Übungsblatt 1 - mit Lösungen

Beschreibende Statistik

Stochastik@MSI
Prof. Dr. Barbara Staehle
Sommersemester 2024
HTWG Konstanz

|Einfache und mittelschwere Aufgaben|

Aufgabe 1.1 Eigenschaften von Merkmalen, 3 Punkte

Geben Sie für jedes Merkmal an, ob es quantitativ diskret, quantitativ stetig, qualitativ ordinal oder qualitativ nominal ist.

a) Anzahl der Insassen in einem PKW bei der Verkehrszählung

b) Höchstgeschwindigkeit eines PWKs

c) Schultypen

d) Temperaturangaben in °C

e) Fassungsvermögen einer Festplatte in MB

f) Zugriffszeiten auf die Daten einer Festplatte in sec

g) Energieeffizienz von Elektrogeräten

h) Trinkmenge eines Menschen pro Tag in Liter

i) Anzahl Likes eines Instagram-Posts

j) Nationalität eines Menschen

k) Anfangsbuchstabe des Vornamens eines Menschen

l) Wohnort eines Menschen

Lösung

a) Anzahl der Insassen in einem PKW bei der Verkehrszählung: quantitativ, diskret

b) Höchstgeschwindigkeit eines PKWs: quantitativ, stetig

c) Schultypen: qualitativ, nominal (Schultypen lassen sich nicht anordnen); ordinal auch richtig (wenn man sagt, dass Gymnasium besser ist als Realschule)

d) Temperaturangaben in ° C: quantitativ, stetig

e) Fassungsvermögen einer Festplatte in MB: quantitativ, diskret

f) Zugriffszeiten auf die Daten einer Festplatte in sec: quantitativ, stetig

g) Energieeffizienz von Elektrogeräten: qualitativ, ordinal (A ist besser als E)

h) Trinkmenge eines Menschen pro Tag in Liter: quantitativ, stetig

i) Anzahl Likes eines Instagram-Posts: quantitativ, diskret

j) Nationalität eines Menschen: qualitativ, nominal (Nationalitäten lassen sich nicht anordnen)

k) Anfangsbuchstabe des Vornamens eines Menschen: qualitativ, ordinal (Buchstaben lassen sich alphabetisch ordnen)

l) Wohnort eines Menschen: qualitativ, nominal (Wohnorte lassen sich nicht anordnen)

AUFGABE 1.2 GELDSCHEINE, 2 PUNKTE

Angenommen, es wären von allen vorhandenen Werten (5 €, 10 €, 20 €, 50 €, 100 €, 200 €, 500 €) gleich viele Geldscheine im Umlauf.

a) Bestimmen Sie den Median des Werts der Geldscheine im Umlauf.

b) Berechnen Sie den Median, der sich nach der Einführung eines 1000 €-Scheins (und davon ebenfalls so viele in den Umlauf gebracht wie alle anderen) ergeben würde.

LÖSUNG

a) $n = 7 = 2 \cdot 3 + 1 \Rightarrow \tilde{x} = x_{3+1} = x_4 = 50\,€$

b) $n = 8 = 2 \cdot 4 \Rightarrow \tilde{x} = \frac{1}{2}(x_4 + x_{4+1}) = \frac{1}{2}(50 + 100) = 75\,€$

AUFGABE 1.3 AN DER FAHRRADBRÜCKE (KLAUSURAUFGABE WS 16/17), 4 PUNKTE

Alice steht an der Konstanzer Fahrradbrücke und zählt die Anzahl der Räder der Fahrzeuge (Einräder, Fahrräder, Dreiräder, Kinderwagen, ...) welche an ihr vorbei rollen.
Ihre Beobachtungen resultieren in folgender Urliste:

$$2, 4, 3, 1, 2, 4, 2, 2, 2, 3.$$

Berechnen Sie für die Beobachtungen von Alice:

a) das arithmetische Mittel

b) den Median

c) den Modalwert

d) das 10%-Quantil

e) das 25%-Quantil

f) das 75%-Quantil

g) den Interquartilabstand

h) die Spannweite

Geben Sie jeweils an, wie Sie die geforderten Charakteristika berechnet haben!

LÖSUNG

Zähle: $n = 10$. Sortierte Liste der Stichprobe:

i	1	2	3	4	5	6	7	8	9	10
x_i	1	2	2	2	2	2	3	3	4	4

a) $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{25}{10} = 2.5$

b) $\tilde{x} = \frac{1}{2}(x_5 + x_6) = \frac{1}{2}(2+2) = 2$

c) $x_m = 2$ (da 2 am meisten vorkommt)

d) $0.1 \cdot 10 = 1 \Rightarrow \tilde{x}_{0.1} = \frac{1}{2}(x_1 + x_2) = \frac{1}{2}(1+2) = 1.5$

e) $0.25 \cdot 10 = 2.5 \Rightarrow \tilde{x}_{0.25} = x_{\lceil 2.5 \rceil} = x_3 = 2$

f) $0.75 \cdot 10 = 7.5 \Rightarrow \tilde{x}_{0.75} = x_{\lceil 7.5 \rceil} = x_8 = 3$

g) $R = max(x) - min(x) = 4 - 1 = 3$

h) $IQR = \tilde{x}_{0.75} - \tilde{x}_{0.25} = 3 - 2 = 1$

AUFGABE 1.4 TASCHENGELD (KLAUSURAUFGABE SS 18)

Frank schreibt für seine Schülerzeitung einen Artikel zum Thema „Taschengeld eines Achtklässlers“. Hierfür befragt er 6 zufällig ausgewählte Schüler der Klasse 8a nach ihrem monatlichen Taschengeld in Euro. Seine Umfrage ergibt die folgende Urliste:

$$25, 10, 30, 25, 35, 25$$

TEILAUFGABE 1.4.1 2 PUNKTE

Berechnen Sie für Frank's Urliste folgende Größen. Stellen Sie Ihren Rechenweg nachvollziehbar dar!

a) Arithmetisches Mittel

b) Median

c) 75%-Quantil

d) empirische Standardabweichung

e) Schätzwerte für den wahren Mittelwert und die wahre Standardabweichung des monatlichen Taschengelds der Grundgesamtheit aller Achtklässler

LÖSUNG

$n = 6$. Sortierte Liste der Stichprobe:

i	1	2	3	4	5	6
x_i	10	25	25	25	30	35

a) $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{150}{6} = 25$

b) $\tilde{x} = \frac{x_3 + x_4}{2} = 25$

c) $0.75 \cdot 6 = 4.5 \Rightarrow \tilde{x}_{0.75} = x_{\lceil 4.5 \rceil} = x_5 = 30$

d) $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{5}((10-25)^2 + 3\cdot(25-25)^2 + (30-25)^2 + (35-25)^2) = \frac{1}{5}(225+0+25+100) = \frac{350}{5} = 70$
$s = \sqrt{s^2} = \sqrt{70} = 8.3666$

e) $\hat{\mu} = \bar{x}, \hat{\sigma^2} = s^2$

TEILAUFGABE 1.4.2 3 PUNKTE

Beantworten Sie folgende Fragen möglichst allgemeinverständlich!

a) Frank berechnet außerdem noch die Spannweite seiner Stichprobe zu $R = 5$ und den Interquartilabstand zu $I = 25$. Machen diese Berechnungen Sinn? Begründen Sie Ihre Meinung!

b) Mittelwert und Median von Franks Daten sind gleich. Ist das immer so, oder ist das Zufall?

c) Was hat der Wert des 75%-Quantils zu bedeuten? Fassen Sie Ihr Ergebnis in Worte.

d) Frank führt seine Umfragen nach dem monatlichen Taschengeld noch in zwei anderen Klassen, den Klassen 8b und 8c, durch. In beiden Fällen erhält er das selbe arithmetische Mittel wie bei Klasse 8a. Im Fall von Klasse 8b erhält er allerdings eine Standardabweichung von 0, im Fall von Klasse 8c erhält er eine Standardabweichung, die deutlich größer ist als die der Klasse 8a. Was schließen Sie hieraus hinsichtlich der Stichproben des monatlichen Taschengelds aus den anderen beiden Klassen?

e) Frank interessiert sich weiterhin für die Schuhgröße der Befragungsteilnehmer, sowie für ihre Mathenote. Er berechnet hierfür die Korrelationskoeffizienten von Schuhgröße und Taschengeld zu $r_{S,T} = 0.875$ und von Mathenote und Taschengeld zu $r_{M,T} = -0.038$. Was schließen Sie hieraus über den Zusammenhang der betrachteten Größen?

f) Grace befragt 3 Schüler nach ihrem Taschengeld und berechnet den arithmetische Mittelwert dieser Stichprobe zu 300 €. Beschreibt diese Zahl die Stichprobe ausreichend gut, oder sollte sie besser noch andere Werte berechnen?

LÖSUNG

a) Quatsch, IQR muss immer kleiner gleich Range sein. Konkret hier hat Frank aber auch die Werte vertauscht: $I = 5$ und $R = 25$.

b) Es ist Zufalls, dass Mittelwert und Median gleich sind, die weichen oft voneinander ab, vor allem für asymmetrische Werteverteilungen. Siehe Beispiel in letzter Teilaufgabe.

c) 75% der Schüler kriegen 30 € oder weniger Taschengeld.
Andere mögliche Lösung: 25% der Schüler bekommen 30 € oder mehr Taschengeld.

d) 8b: alle kriegen gleich viel Taschengeld (25), 8c: Werte schwanken stärker, es gibt also mehr Kinder die deutlich unter bzw. über 25 € kriegen.

e)
- Schuhgröße und Taschengeld sind (deutlich) positiv korreliert, heißt dass ein Schüler mit größeren Füßen tendenziell mehr Taschengeld bekommt.
- Mathenote und Taschengeld sind (sehr schwach) negativ korreliert bis eher unabhängig, heißt dass man von der Mathenote nicht aufs Taschengeld rückschließen kann.

f) Wenn Mittelwert 300 ist, ein Wert 890, könnte die Stichprobe z.B. 5,5,890 sein. Daher hilft es, sich z.B. Median und Modalwert, beide 5, anzusehen.

AUFGABE 1.5 SPORTWAGEN (KLAUSURAUFGABE WS 17/18)

Charlie besucht die IAA (Internationale Automobilausstellung). Er interessiert sich für Sportwagen und sucht daher Informationen zu den Höchstgeschwindigkeiten der vorgestellten Autos.

Am Stand von Hersteller 1 analysiert er die Datenblätter von 10 verschiedenen Fahrzeugen, denen er folgende Höchstgeschwindigkeiten entnimmt:

$$250, 330, 250, 350, 270, 300, 260, 330, 200, 400$$

TEILAUFGABE 1.5.1 2 PUNKTE

Berechnen Sie für die Stichprobe der von Charlie ermittelten Höchstgeschwindigkeiten folgende Größen. Stellen Sie Ihren Rechenweg nachvollziehbar dar!

a) Arithmetisches Mittel

b) Median

c) 90%-Quantil

d) Standardabweichung

LÖSUNG

$n = 10$. Sortierte Liste der Stichprobe:

i	1	2	3	4	5	6	7	8	9	10
x_i	200	250	250	260	270	300	330	330	350	400

a) $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{2940}{10} = 294$

b) $\tilde{x} = \frac{x_5 + x_6}{2} = \frac{270+300}{2} = 285$

c) $0.9 \cdot 10 = 9 \Rightarrow \tilde{x}_{0.9} = \frac{x_9 + x_10}{2} = \frac{350+400}{2} = 375$

d) $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{9}(\ldots) = 349.333$
$s = \sqrt{s^2} = 59.104$

TEILAUFGABE 1.5.2 3 PUNKTE

Gefragt sind Beschreibungen in Ihren eigenen Worten (Zielgruppe: nicht-technisches Publikum).

a) Nennen Sie **zwei** Fakten, wie die von Ihnen berechneten Größen einzeln oder gemeinsam betrachtet die von Charlie erhobene Stichprobe der Höchstgeschwindigkeiten charakterisieren.

b) Charlie entnimmt aus einem Datenblatt von Hersteller 2 ebenfalls die Höchstgeschwindigkeiten von 10 verschiedenen Fahrzeugen und berechnet den Mittelwert dieser Höchstgeschwindigekeiten zu 294 sowie die Standardabweichung zu 20. Was schließen Sie hieraus hinsichtlich des Unterschieds zwischen den Fahrzeugen der beiden Hersteller?

c) Charlie betrachtet weiterhin die Preise der Reifen welche für die Fahrzeuge von Hersteller 1 zugelassen sind, sowie die Umweltfreundlichkeit des Fahrzeugs auf einer Skala von 0 (gar nicht) bis 10 (sehr).
Er berechnet hierfür die Korrelationskoeffizienten von Höchstgeschwindigkeit und Reifenpreis zu $r_{G,R} = 0.853$ und von Höchstgeschwindigkeit und Umweltfreundlichkeit zu $r_{G,U} = -1.137$. Was schließen Sie hieraus über den Zusammenhang der betrachteten Größen?

LÖSUNG

a)
- Mittelwert ist deutlich größer als der Median, es gibt also unverhältnismäßige Ausreiser die den Wert nach oben ziehen.
- Vor allem Vergleich von Mittelwert / Median und 90%-Quantil zeigt, dass es sehr viel schnellere Werte als die im Mittel gibt.
- Standardabweichung $\approx 60 \Rightarrow$ im Mittel weicht die Geschwindigkeit der Autos ungefähr 60 kmh vom Mittelwert ab.

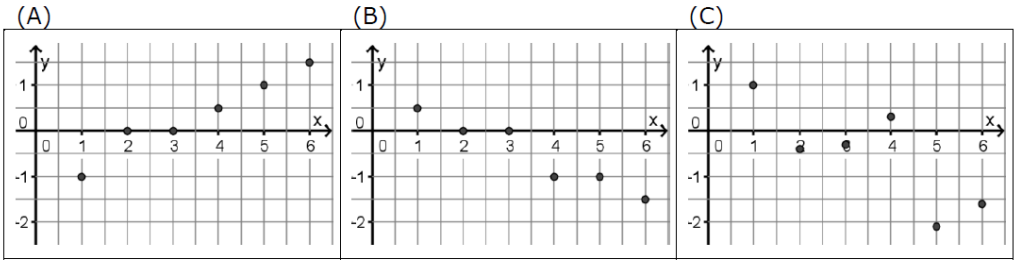
b) Mittelwert und Stichprobegröße sind gleich, die Standardabweichung ist kleiner, daher weichen die Höchstgeschwindigkeiten weniger stark vom Mittelwert ab, die Fahrzeuge von Hersteller 2 sind also in sich ähnlicher (schnell) wie die von Hersteller 1.

c)
- Geschwindigkeit und Reifenpreise sind positiv korreliert, heißt dass ein schnelleres Auto mit einer hohen Wahrscheinlichkeit auch teurere Reifen braucht.
- Der Korrelationskoeffizient von Geschwindigkeit und Umweltfreundlichkeit wäre rund um -1 zu erwarten, kann aber nicht kleiner als -1 werden, daher ist der Wert Quatsch.

|Mittelschwere und schwere Aufgaben|

Aufgabe 1.6 Punktwolken

Teilaufgabe 1.6.1 3 Punkte



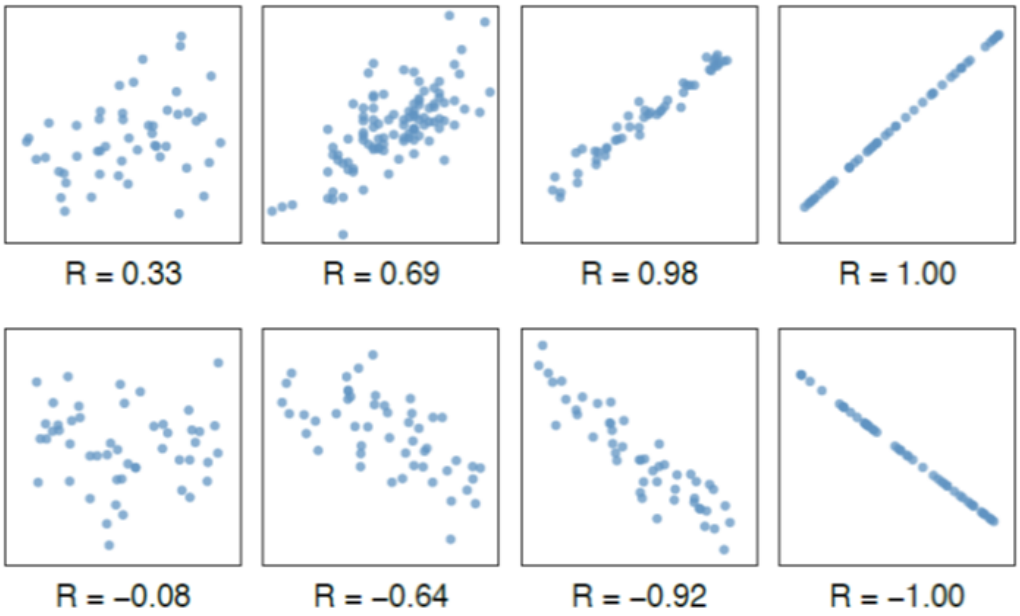
Bei welcher der dargestellten Punktwolken (A), (B) oder (C) erhält man als Korrelationskoeffizienten $r_{x,y} = -0,966$? Begründen Sie Ihre Meinung und nennen Sie für die beiden anderen Punktwolken jeweils einen Ablehnungsgrund.

Lösung

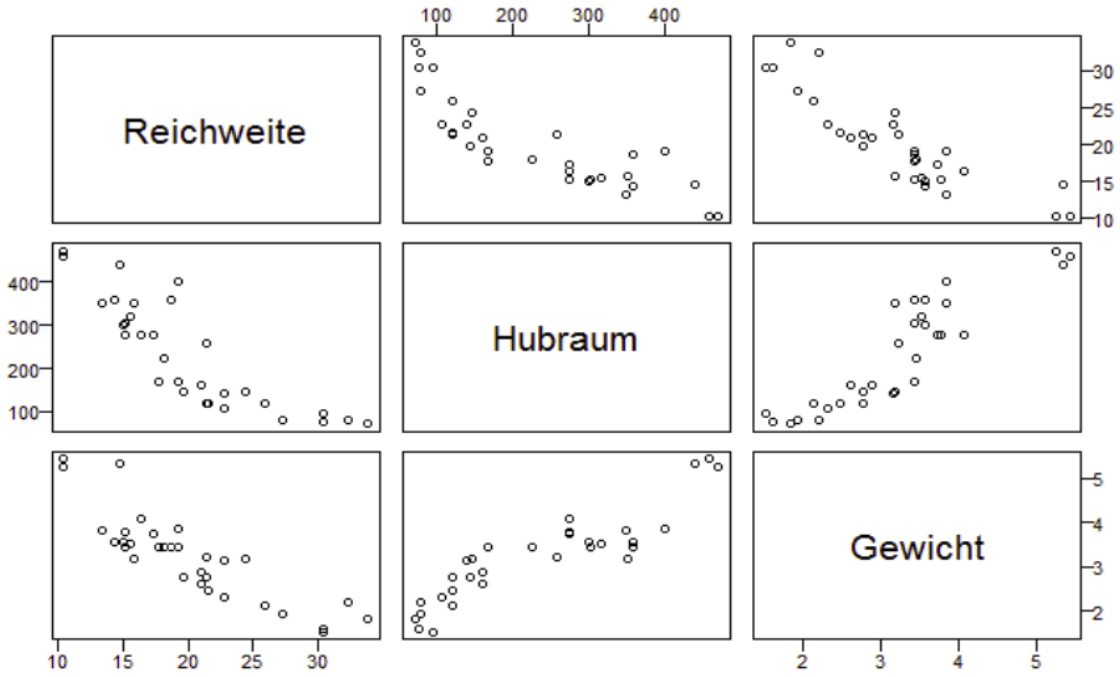
Bei Punktwolke B erhält man $r_{x,y} = -0,966$, da der Trend erkennbar linear negativ ist. Punktwolke A hat eine aufsteigende Trendlinie; deshalb wäre $r_{x,y} > 0$. Bei Punktwolke C ist die Streuung der Punkte größer; deshalb wäre $|r_{x,y}| < 0,966$, also weniger stark korreliert.

Teilaufgabe 1.6.2 3 Punkte

Lösung



TEILAUFGABE 1.6.3 3 PUNKTE



Die abgebildete Matrix stellt Punktwolken für einige Eigenschaften einer Auswahl verschiedener Autotypen des gleichen Herstellers dar. Der Plot oben rechts z.B. zeigt auf der x-Achse den Faktor Gewicht, auf der y-Achse den Faktor Reichweite. Ein Punkt entspricht einem Auto, geeignete Einheiten fehlen, diese dürfen Sie sich selbst ausdenken.

Welche Aussagen über die Zusammenhänge zwischen diesen drei Faktoren lassen sich aus der Grafik ableiten?

LÖSUNG

- Reichweite und Hubraum sind negativ korreliert, ein Auto mit großem Hubraum hat mit einer großen Wahrscheinlichkeit eine kleine Reichweite, je größer der Hubraum desto kleiner ist tendenziell die Reichweite.
- Reichweite und Gewicht sind negativ korreliert, ein schweres Auto hat mit einer großen Wahrscheinlichkeit eine kleine Reichweite, je schwerer das Auto desto kleiner ist tendenziell die Reichweite.
- Gewicht und Hubraum sind positiv korreliert, ein Auto mit großem Hubraum hat mit einer großen Wahrscheinlichkeit ein hohes Gewicht, je größer der Hubraum desto schwerer ist tendenziell das Auto.
- Korrelationen sind symmetrisch, diese 3 Zusammenhänge sind die einzig dargestellten.
- Welche der Korrelationen die stärkste ist, ist schwierig zu beurteilen, da die Darstellungen nicht normiert sind.

AUFGABE 1.7 KLAUSURNOTEN (KLAUSURAUFGABE SS19)

Prof. Schmidt liest für alle Studierenden des Studiengangs „Master Super-Informatik“ die Vorlesungen „Mathematik 1“ und „Mathematik 2“.

Um die Noten der beiden Vorlesungen vergleichen, analysiert sie die Noten, welche 6 zufällig ausgewählte Studierende $(s_1, s_2, \ldots, s_6)$ in den beiden Klausuren jeweils erreichten. Sie erhält die folgende Tabelle:

Studierende(r)	s_1	s_2	s_3	s_4	s_5	s_6
Note Mathematik 1	1.3	5.0	1.3	2.7	4.0	3.7
Note Mathematik 2	2.0	3.0	1.0	2.0	1.0	2.7

TEILAUFGABE 1.7.1 2 PUNKTE

Berechnen Sie **nur für die Noten der Vorlesung Mathematik 1** folgende Größen. Stellen Sie Ihren Rechenweg nachvollziehbar dar, bzw. geben Sie die Verwendung des Taschenrechners oder eines anderen elektronischen Tools an!

a) Arithmetisches Mittel

b) Alle Quartile

c) 90%-Quantil

d) empirische Standardabweichung

LÖSUNG

$n = 6$. Sortierte Liste der Stichprobe:

Studierende(r)	s_1	s_2	s_3	s_4	s_5	s_6
Note Mathematik 1	1.3	1.3	2.7	3.7	4.0	5.0

a) $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{18}{6} = 3$

b) via Taschenrechner oder sortierte Liste

- $Q1 : 1.3$ (25%-Quantil: $\tilde{x}_{0.25} = x_{\lceil 6*0.25 \rceil} = x_2 = 1.3$)
- $Q2 : 3.2$ (Median: $\tilde{x} = (x_3 + x_4)/2 = 3.2$)
- $Q3 : 4.0$ (75%-Quantil: $\tilde{x}_{0.75} = x_{\lceil 6*0.75 \rceil} = x_5 = 4.0$)

c) $0.9 \cdot 6 = 5.4 \Rightarrow \tilde{x}_{0.9} = x_{\lceil 5.4 \rceil} = x_6 = 5.0$

d) $s = 1.5073$ (TR) Falscher Ansatz: $\sigma = 1.37598$

TEILAUFGABE 1.7.2 3 PUNKTE

Beantworten Sie folgende Fragen in ganzen Sätzen und möglichst allgemeinverständlich!

a) Was bedeutet der Wert des 90%-Quantils (Ihr Ergebnis aus Aufgabe 1.9.2c) für die Noten von Mathematik 1?

b) Prof. Schmidt berechnet für die Noten der Vorlesung Mathematik 2 folgende Größen:

$$\bar{x} = 2.0, \quad (Q1,\ Q2,\ Q3) = (1.0,\ 2.0,\ 2.7), \quad \tilde{x}_{0.9} = 3.0, \quad s = 0.8462$$

Verwenden Sie diese Zahlen, sowie Ihre eigenen Berechnungen aus Aufgabe 1.9.2 um **zwei** Gemeinsamkeiten oder Unterschiede für die Noten in Mathematik 1 und 2 abzuleiten. Begründen Sie Ihre Meinung!

c) Fertigen Sie eine kleine (nicht genaue!!) Skizze an, welche die Noten in Mathematik 1 und Mathematik 2 **graphisch** vergleicht. Beschreiben Sie, welche Werte Sie wie darstellen (Achsen, Art der Darstellung, ...) und was die sichtlichen Unterschiede bedeuten.

d) Welcher der folgenden Werte ist der korrekte empirische Korrelationskoeffizienten für die Noten in Mathematik 1 und Mathematik 2 $r_{1,2}$ (für die obige Stichprobe)? Begründen Sie Ihre Meinung.

$$r_{1,2} = \quad 0 \quad -0.571 \quad 0.423 \quad 1.1 \quad 0.952$$

LÖSUNG

a) $\tilde{x}_{0.9} = 5.0$: 90% aller Studierenden erhalten eine 5.0 oder besser, bzw. 10% aller Studierenden erhalten eine 5.0 oder schlechter (nicht sehr sinnvoll).

b)
- Bei Mathe 2 (im Vergleich zu Mathe 1) sind die Noten im Durchschnitt deutlich besser, sieht man am Vergleich von Mittelwert, allen Quantilen, Min, Max.
- Bei Mathe 2 (im Vergleich zu Mathe 1) sind Standardabweichung ist kleiner, IQR, Range auch, Noten sind homogener.
- Bei beiden Vorlesungen ist der Median größer als der Mittelwert, heißt, es gibt im Verhältnis mehr gute Noten, die die wenigen schlechten Noten im Mittel wieder ausgleichen.

c) Ich würde die Noten als Punktwolke darstellen. Daran erkennt man a) die positive Korrelation b) dass die Punkte überwiegend unter der Winkelhalbierenden liegen, was zeigt, dass die Noten in Mathe2 überwiegend besser sind als die in Mathe1

d) $r_{1,2} = 0.952$, da die Daten einen deutlich positiven Zusammenhang (je größer M1 desto größer M2) zeigen
alternative Begründung über Ausschlussverfahren: Wert 1.1 ist nicht möglich für eine Korrelation, keine Korrelation (0) so sehen die Daten nicht aus, genauso wenig negativ korreliert (-0.571), 0.423 wäre möglich, aber die Korrelation ist tatsächlich stärker, damit 0.952.

AUFGABE 1.8 JOBSUCHE (KLAUSURAUFGABE WS20/21)

Sie suchen nach Ihrem Studium einen neuen Job, der bestimmte Anforderungen erfüllen soll.

- Der neue Job soll in einer attraktiven Stadt sein: Sie bewerten die Stadt in dieser Hinsicht mit Punkten von 1 (furchtbar) bis 10 (total toll).
- Natürlich ist Ihnen auch das Gehalt wichtig: Sie notieren das (geschätzte) Brutto-Gehalt in Tausend Euro ($55 \triangleq 55\,000$).
- Und die Tätigkeit soll interessant sein: Auch hier vergeben Sie Punkte von 1 (langweilig) bis 10 (genau Ihr Ding).

Nach zwei Wochen Suche haben Sie sich auf folgende 8 Jobs eingeschränkt und diese wie folgt bewertet:

Job	J_1	J_2	J_3	J_4	J_5	J_6	J_7	J_8
Attraktivität der Stadt	7	4	10	10	9	3	9	6
Gehalt	65	60	40	70	45	40	65	55
interessant	3	10	9	1	5	10	2	3

TEILAUFGABE 1.8.1 3 PUNKTE

Berechnen Sie **nur für Ihre Punktevergabe der Attraktivität der Städte** (Zeile 1 der Tabelle) folgende Größen. Stellen Sie Ihren Rechenweg nachvollziehbar dar, bzw. geben Sie die Verwendung des Taschenrechners (TR), bzw. des genutzten Tools an!:

a) Modalwert

b) Arithmetisches Mittel

c) empirische Standardabweichung

d) Alle Quartile

e) 60%-Quantil

LÖSUNG

a) Modalwert: 10

b) $\bar{a} = 7.25$

c) $a_s = 2.7124$ falscher Wert: $\sigma_a = 2.5372$

d) $Q1 = 4, Q2 = 7, Q3 = 9$ (Matlab)

e) Sortierte Liste: $3, 4, 6, 7, 9, 9, 10, 10$
$0.6 \cdot 8 = 4.2 \Rightarrow a_{0.6} = a_5 = 9$ Matlab: 9

TEILAUFGABE 1.8.2 6 PUNKTE

a) Für welchen der 8 Jobs würden Sie sich auf Basis dieser Daten entscheiden? Begründen Sie Ihre Meinung (es gibt keine richtige oder falsche Antwort).

b) Ihre Freunde Alice und Bob haben sich jeweils auch 8 Jobs ausgesucht und die Attraktivität der Städte ebenso mit 1-10 bewertet. Alice berechnet den Mittelwert der Städte als $\overline{a_B} = 7.25$ und die entsprechende Standardabweichung zu $s_{a_B} = 5$. Bob berechnet den Mittelwert der Städte als $\overline{a_C} = 5$ und die entsprechende Standardabweichung zu $s_{a_C} = 0$. Was können Sie aus diesen Werten über die Attraktivität der Städte von Alice und Bob im Vergleich zu „ihren“ Städten sagen?

c) **Schätzen** Sie die empirischen Korrelationskoeffizienten $r_{A,G}, r_{A,I}, r_{G,I}$ zwischen „Attraktivität der Stadt“ und „Gehalt“, „Attraktivität der Stadt“ und „interessant“ sowie „Gehalt“ und „interessant“ für die ausgewählten Jobs.
Rechnen Sie diese nicht aus, sondern wählen Sie unter den folgenden Werten. Begründen Sie Ihre Meinung!

$r_{A,G}$	a) 0.1983	b) 1.983	c) -0.9308	d) 0.0093
$r_{A,I}$	a) 5.599	b) -0.5599	c) 0.5599	d) 0.0055
$r_{G,I}$	a) 0.7032	b) 0.0073	c) -0.7032	d) -7.0320

LÖSUNG

a) keine Musterlösung, begründen Sie Ihre Meinung nur sinnvoll.

b) Die Städte von mir Alice sind im Mittel gleich interessant, allerdings streut die Stichprobe stärker, die Attraktivitäten sind verschiedener da Standardabweichung größer.
Stichprobe von Bob : Standardabweichung $= 0$, heißt alle Werte haben die gleiche Attraktivität 5.

c)
- $r_{A,G} = 0.1983$, weil Werte schwach, aber doch etwas zusammenhängen
  positiv korreliert, je attraktiver die Stadt, desto höher das Gehalt (vielleicht weil Stadt teuer)
- $r_{G,I} = -0.5599$, weil tendenziell je besser bezahlt der Job desto uninteressanter, aber nicht immer
  negativ korreliert, je interessanter die Stadt, desto weniger gut bezahlt der Job (aber nicht so stark wie Gehalt)
- $r_{A,I} = -0.7032$, weil tendenziell je attraktiver die Stadt desto uninteressanter der Job, aber nicht immer
  negativ korreliert, je attraktiver die Stadt desto weniger interessant der Job, allerdings schwächerer Zusammenhang als die anderen.

Alternativ: Auch Ausschlussverfahren möglich: Korrelationskoeffizient muss kleiner als 1 sein ...

AUFGABE 1.9 AUTOTESTS (KLAUSURAUFGABE WS19/20)

Alice liest auf der Webseite eines Automagazins einen Testbericht, der 5 verschiedene Autos $(a_1, a_2, \ldots, a_5)$ hinsichtlich ihres Spritverbrauchs vergleicht. Konkret wurde überprüft, ob der Benzinverbrauch in Liter pro 100 km Fahrleistung der Herstellerangabe entspricht:

Auto	a_1	a_2	a_3	a_4	a_5
Verbrauch [l/100km] laut Hersteller	4.2	3.9	4.3	4.1	4.1
Verbrauch [l/100km] laut Test	4.8	4.1	4.8	4.5	4.4

TEILAUFGABE 1.9.1 1 PUNKT

Geben Sie an, welche der Eigenschaften **qualitativ, quantitativ, diskret, stetig** auf das ebenfalls untersuchte Merkmal „Anzahl der Räder des Fahrzeugs“ zutrifft bzw. zutreffen. Begründen Sie Ihre Wahl (kurz).

LÖSUNG

„Anzahl der Räder des Fahrzeugs“ ist quantitativ und diskret.

Begründung: Räder werden gezählt, der Wertebereich ist endlich (im Streitfall auch unendlich) auf jeden Fall aber abzählbar.

TEILAUFGABE 1.9.2 3 PUNKTE

Berechnen Sie **nur für die Verbrauchsangaben des Herstellers** folgende Größen.

a) Arithmetisches Mittel b) Alle Quartile c) 10%-Quantil
d) Spannweite e) empirische Standardabweichung

LÖSUNG

Sortierte Liste der Stichprobe:

Auto	a_1	a_2	a_3	a_4	a_5
Verbrauch [l/100km] laut Hersteller	3.9	4.1	4.1	4.2	4.3

a) $n = 5$; $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{20.6}{5} = 4.12$

b) via Tool oder sortierte Liste

- $Q1 : 4.1$ (25%-Quantil: $\tilde{x}_{0.25} = x_{\lceil 5*0.25 \rceil} = x_2 = 4.1$ (TR: 4))
- $Q2 : 4.1$ (Median: $\tilde{x} = x_3 = 4.1$)
- $Q3 : 4.2$ (75%-Quantil: $\tilde{x}_{0.75} = x_{\lceil 5*0.75 \rceil} = x_4 = 4.2$ (TR: 4.25))

c) $0.1 \cdot 5 = 0.5 \Rightarrow \tilde{x}_{0.1} = x_{\lceil 0.5 \rceil} = x_1 = 3.9$

d) $R = \max - \min = 4.3 - 3.9 = 0.4$

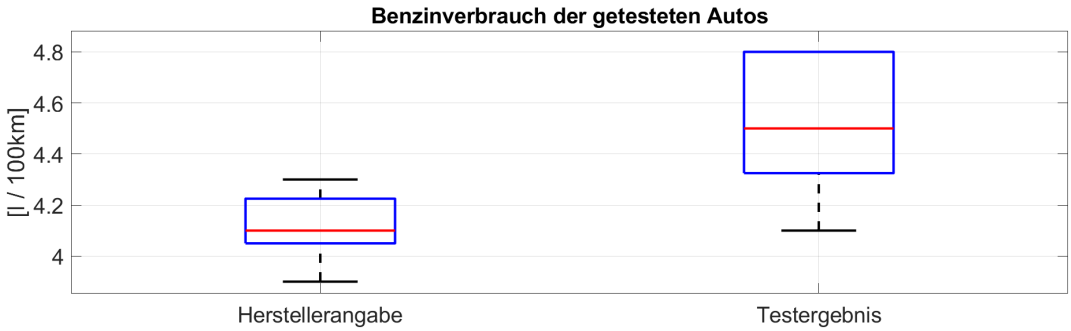
e) $s = 0.1483$ (TR) Falscher Ansatz: $\sigma = 0.1327$

TEILAUFGABE 1.9.3 5 PUNKTE

Beantworten Sie folgende Fragen in ganzen Sätzen und möglichst allgemeinverständlich!

a) Was bedeutet der Wert der empirischen Standardabweichung (Ihr Ergebnis aus Aufgabe 1.9.2**??**) für den Benzinverbrauch eines Autos (laut Hersteller)?

b) Alice interessiert sich dafür, inwieweit die Verbrauchsangaben der Hersteller und der im Test erzielte Benzinverbrauch vergleichbar sind. Daher erstellt Sie folgende Grafik:



Beschreiben Sie anhand dieser Grafik (und ggf. unter Verwendung Ihrer eigenen Berechnungen aus Aufgabe 1.9.2) **zwei** Gemeinsamkeiten oder Unterschiede für den Benzinverbrauch der untersuchten Autos laut Hersteller und laut Test. Können diese Sachverhalte Sinn machen? Begründen Sie Ihre Meinung!

c) Welcher der folgenden Werte ist der korrekte empirische Korrelationskoeffizienten für den Benzinverbrauch eines Autos laut Hersteller und laut Test $r_{H,T}$ (für die vorliegende Stichprobe)? Kreisen Sie den richtigen Wert bzw. streichen Sie falsche Werte durch. Begründen Sie Ihre Meinung.

$$r_{H,T} = \quad 0.0001 \quad 0.961 \quad 0.235 \quad 1.1 \quad -0.521$$

d) Um abschätzen zu können, ob man aus der Herstellerangabe des Benzinverbrauchs das Testergebnis ausrechnen kann, berechnet Alice die Regressionsgerade für die beiden Datensätze und erhält hierfür das Bestimmtheitsmaß $R^2 = 0.92$. Was bedeutet dieses? Ist die Anwendung der linearen Regression hier sinnvoll und zulässig? Begründen Sie Ihre Meinung.

LÖSUNG

a) $s = 0.1483$: die typische Abweichung vom Mittelwert 4.12 ist ±0.15 und tatsächlich deckt das grob den Bereich ab, in dem alle Werte liegen.

b)
- Beim tatsächlichen Test (im Vergleich zu den Herstellerangaben) ist der Verbrauch immer höher, sieht man am Vergleich von Mittelwert, allen Quantilen, Min, Max.
- Beim tatsächlichen Test (im Vergleich zu den Herstellerangaben) ist die Standardabweichung größer, IQR, Range auch, der Verbrauch ist also verschiedener als laut Hersteller.

c) 0.961 ist richtig. Erkennt man daran, dass die ein höherer Spritverbrauch laut Hersteller tendenziell auch einen höheren Verbrauch im Test bedeutet.

d) Mit einem so hohen Bestimmtheitsmaß sollte man mit der linearen Regression eine gute Passgenauigkeit, also eine gute Übereinstimmung zwischen Daten und Gerade erzielen (sieht man ja auch an $r = 0.96$). Aber trotzdem bitte die Geraden angucken!!

AUFGABE 1.10 RESPOSITORIES (KLAUSURAUFGABE SS21)

Alice arbeitet für den Webhoster Host123 und ist dafür zuständig, den automatischen Build-Prozess für Kunden-Webapplikationen zu optimieren. Hierfür analysiert sie in 10 zufällig ausgewählten Kundenrepositories die Anzahl der in den am häufigsten genutzten Programmiersprachen Java, Python, Ruby gespeicherten Dateien.

Ihre Ergebnisse fasst sie in der folgenden Tabelle zusammen:

Repository	R_1	R_2	R_3	R_4	R_5	R_6	R_7	R_8	R_9	R_{10}
Java	25	17	25	29	20	15	11	17	16	16
Python	11	11	13	9	10	7	3	8	9	4
Ruby	0	4	0	0	0	2	2	1	3	0

TEILAUFGABE 1.10.1 8 PUNKTE

Berechnen Sie **für die Anzahl der Java-Dateien** (Zeile 1 der Tabelle) die im Folgenden gesuchten Größen. Stellen Sie Ihren Rechenweg nachvollziehbar dar, bzw. geben Sie die Verwendung des Taschenrechners (TR), bzw. des genutzten Tools an!

LÖSUNG

a) Modalwert: 16.0, mit Häufigkeit 2.0

b) Mittelwert: $\bar{j} = 19.1$

c) Median: $\tilde{j} = 17.0$

d) 90%-Quantil: $\tilde{j}_{0.9} = 27.0$

e) empirische Standardabweichung: $s_j = 5.567$ falscher Wert: $\sigma_j = 5.281$

f) Quartile: $Q1 = 16.0,\ Q2 = \tilde{j} = 17.0,\ Q3 = 22.5$

g) Interquartilsabstand: $I = Q3 - Q1 = 6.5$

h) Spannweite: $\min(j) = 11.0, \max(j) = 29.0 \Rightarrow R = 18.0$

TEILAUFGABE 1.10.2 12 PUNKTE

a) (2 Punkte) Formulieren Sie mit Hilfe der Kenngrößen, die Sie in Aufgabe 1.10.1 ausgerechnet haben, **zwei** Aussagen über die Anzahl der Java-Dateien in den untersuchten Repositories. Schreiben Sie also zwei Sätze auf, die Sie mit Hilfe der Zahlen begründen können. Begründen Sie Ihre Meinung (es gibt keine richtige oder falsche Antwort).

b) (2 Punkte) Finden Sie jeweils einen Unterschied, bzw. eine Gemeinsamkeit zwischen der Anzahl der Python- und der Python-Dateien und der Java und der Ruby- Dateien in den Repositories, indem Sie Ihre Berechnungen aus Aufgabe 1.10.1 mit den folgende Kennwerten für Java und Ruby vergleichen. Schreiben Sie hierzu zwei Sätze auf.

Sprache	Mittelwert	Median	Std	IQR	Range
Python	8.5	9.0	3.136	3.0	10.0
Ruby	1.2	0.5	1.476	2.0	4.0

c) (2 Punkte) Wenn Sie die Unterschiedlichkeiten und Gemeinsamkeiten betreffend der Anzahl der Dateien in den verschiedenen Programmiersprachen graphisch darstellen sollten, wäre ein Boxplot, ein Violinplot oder keiner der beiden geeignet? Begründen Sie Ihre Meinung.

d) (3 Punkte) Die Scatter-Plots in Abbildung 1 illustrieren den Zusammenhang zwischen der Anzahl der Dateien in

(1) Java und Python	(2) Java und Ruby	(3) Python und Ruby

Geben Sie an, welches der Bilder (A,B,C,D) welchen Zusammenhang darstellt. Begründen Sie Ihre Meinung.

e) (3 Punkte) **Schätzen** Sie die empirischen Korrelationskoeffizienten $r_{J,P}, r_{J,R}, r_{P,R}$ zwischen der Anzahl der Dateien in Java und Python, Java und Ruby, sowie Python und Ruby.

Rechnen Sie diese nicht aus, sondern wählen Sie unter den folgenden Werten. Interpretieren Sie den Wert (was sagt dieser über den Zusammenhang der beiden Metriken aus?) Begründen Sie Ihre Meinung.

$r_{J,P}$	a) -0.598	b) 0.998	c) 0.678	d) -0.072
$r_{J,R}$	a) -0.598	b) 0.998	c) 0.678	d) -0.072
$r_{P,R}$	a) -0.598	b) 0.998	c) 0.678	d) -0.072

LÖSUNG

a) Musterlösung schwer. Vorstellbare Stichpunkte:

- Die typische Anzahl von Java-Dateien pro Repository liegt bei 19.1.
- Aus dem Vergleich von Median 17.0 und Mittelwert 19.1 sieht man, dass es ein paar wenige große Repositories geben muss, die den Mittelwert nach oben ziehen.
- 50% aller Repository-Größen liegen zwischen 16.0, und 22.5
- ...

b) Musterlösung schwer. Vorstellbare Stichpunkte:

- Aus dem Vergleich der Mittelwerte sieht man, dass Python- und Ruby-Repositories typischerweise viel weniger Dateien enthalten als Java-Repositories.
- Bei allen drei Repositories unterscheiden sich Range und IQR deutlich, heißt, es gibt in allen Sprachen Repositories, die deutlich mehr oder deutlich weniger Dateien beeinhalten als die anderen.
- ...

c) Violinplot nicht unbedingt, weil der mit KDE funktioniert, und KDE stetige ZV annimmt. Anzahl der Dateien ist diskret. Boxplot könnte ganz gut funktionieren, stellt ja auf einen Blick Median, die Quantile und Ausreißer dar.

d) siehe Abbildung 1

e)
- $r_{J,P} = 0.678$, weil 0.998 ausgeschlossen werden kann, da der Zusammenhang ja nicht fast linear ist. Zusammenhang ist positiv und eher deutlich, da Repositories mit vielen Java Dateien tendenziell auch viele Python-Dateien enthalten, damit fallen auch -0.598 und -0.072 weg.
- $r_{J,R} = -0.598$, weil 0.998 ausgeschlossen werden kann, da der Zusammenhang ja nicht fast linear ist. Zusammenhang ist negativ und eher deutlich, da Repositories mit vielen Java Dateien tendenziell wenige Ruby-Dateien enthalten,damit fallen auch 0.678 und -0.072 weg.
- $r_{P,R} = -0.072$, weil 0.998 ausgeschlossen werden kann, da der Zusammenhang ja nicht fast linear ist. Zusammenhang ist sehr schwach, damit fällt 0.678 weg, Ausschlussverfahren erlaubt, auch -0.598 zu streichen, oder man sieht auch einen leicht negativen Zusammenhang.

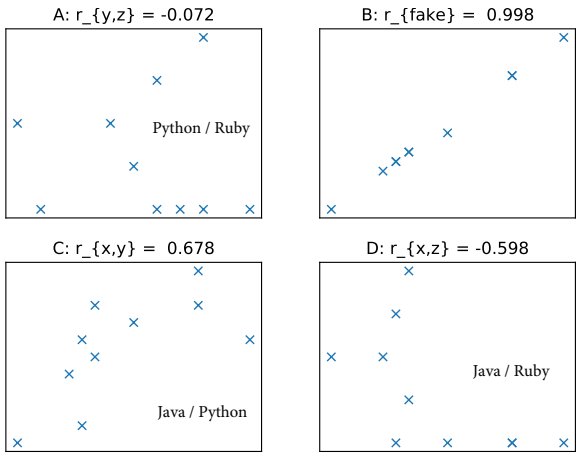


Abbildung 1: Welcher Scatterplot entspricht welcher Sprachkombination?

|Digitalaufgaben|

Aufgabe 1.11 Ausbildung und Gehälter, 3 Punkte

Fünf Mitglieder eines Sportclubs gehen der Frage nach, ob zwischen ihrer Schul- und Ausbildungszeit und ihrem Jahreseinkommen ein statistischer Zusammenhang besteht. Das Ergebnis der anonymen Befragung ist in folgender Tabelle wiedergegeben.

Ausbildungsdauer X	9	13	15	18	20
Jahresgehalt Y [1000 €]	18	37	61	125	59

a) Berechnen Sie den empirischen Korrelationskoeffizient der beiden untersuchten Merkmale. Interpretieren Sie diesen Wert!

b) Bestimmen Sie eine lineare Regressionsfunktion und zeichnen Sie diese. Bewerten Sie die Passgenauigkeit dieser Regressionsgerade optisch und durch das Bestimmtheitsmaß.

Lösung

a) Der empirische Korrelationskoeffizient berechnet sich als

$$r_{x,y} = \frac{s_{x,y}}{s_x s_y}.$$

MATLAB: `corrcoef` und die Einträge der Nebendiagonalen verwenden.

TR (TI): Menü `stat-reg`→`2-Var Stats` (wenn die Daten für x und y schon in den Spalten L1 und L2 eingegeben waren)

Per Hand sind folgende Berechnungsschritte notwendig:

- $\bar{x} = \frac{1}{5}(9+13+15+18+20) = \frac{75}{5} = 15$
- $\bar{y} = \frac{1}{5}(18+37+61+125+59) = \frac{300}{5} = 60$
- $s_{x,y} = \frac{1}{5-1}\sum_{i=1}^{5}(x_i-\bar{x})(y_i-\bar{y})$
  $= \frac{1}{4}[(9-15)(18-60)+(13-15)(37-60)+(15-15)(61-60)+(18-15)(125-60)+(20-15)(59-6$
  $= \frac{1}{4}(6\cdot 42+2\cdot 23+0\cdot 1+3\cdot 25+5\cdot 1) = \frac{1}{4}(252+46+0+195+(-5)) = \frac{488}{4} = 122$

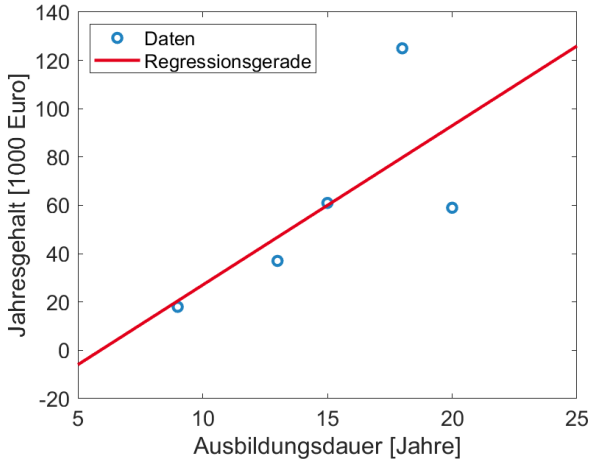
- $s_x = \sqrt{\frac{1}{5-1}\sum_{i=1}^{5}(x_i-\bar{x})^2} = \sqrt{\frac{1}{4}((9-15)^2+(13-15)^2+(15-15)^2+(18-15)^2+(20-15)^2)}$
  $= \sqrt{\frac{1}{4}(36+4+0+9+25)} = \sqrt{\frac{74}{4}} = \sqrt{\frac{37}{2}} = 4.3012$
- $s_y = \sqrt{\frac{1}{5-1}\sum_{i=1}^{5}(y_i-\bar{y})^2} = \sqrt{\frac{1}{4}((18-60)^2+(37-60)^2+(61-60)^2+(125-60)^2+(59-60)^2)}$
  $= \sqrt{\frac{1}{4}(42^1+23^2+1^2+65^2+1^2)} = \sqrt{1630} = 40.3733$
- $r_{x,y} = \frac{s_{x,y}}{s_x s_y} = \frac{122}{4.3012 \cdot 40.3733} = 0.70256$

Ein Korrelationskoeffizient von mehr als 0.7 zeigt, dass Ausbildungsdauer und Jahresgehalt stark korreliert sind, eine Person mit einer längeren Ausbildung hat also mit einer höheren Wahrscheinlichkeit auch ein höheres Jahresgehalt.

b) **MATLAB:** `regression` und oder `plotregression`.

Per Hand sind folgende Berechnungsschritte notwendig::

- $k = r_{x,y} \cdot \frac{s_y}{s_x} = 0.70256 \cdot \frac{40.3733}{4.3012} = 6.5946$
- $d = \bar{y} - k\bar{x} = 60 - 6.5946 \cdot 15 = -38.9189$
- Regressionsgerade: $f(x) = kx + d = 6.5946 - 38.9189x$
- Bestimmtheitsmaß: $R^2 = r_{x,y}^2 = 0.70256^2 = 0.4936$



Sowohl R^2 als auch der optische Vergleich zeigen, dass die Regressionsgerade „ganz gut“ passt. Allerdings ist die Passung für längere Ausbildungszeiten deutlich schlechter. Das wird erst durch die optische Analyse sichtbar!

Aufgabe 1.12 Fernsehen und Agressionen, 3 Punkte

In einer Studie zur Auswirkung von YouTube-Filmen mit gewalttätigen Szenen auf das Sozialverhalten von Kindern wurden ein Aggressivitätsmaß Y (auf einer Skala von 0-10), die Zeitdauer X (in Minuten), während der das Kind gewöhnlich solche Filme sieht, und das Geschlecht Z des Kindes (0 männlich, 1 weiblich) erfasst.

Die Ergebnisse in einer zufällig gewählten Testgruppe waren wie folgt:

i	1	2	3	4	5	6	7	8	9	10	11	12	13
x_i	10	50	30	70	80	60	90	40	10	20	30	50	60
y_i	4	5	2	6	6	8	7	2	7	3	5	1	3
z_i	0	0	0	0	0	0	0	1	1	1	1	1	1

Verwenden Sie diese Testergebnisse, für eine (empirisch begründete) Aussage zum Thema "macht YouTube agressiv"?

Empfohlene Vorgehensweise:

a) Zeichnen Sie ein Streudiagramm für die 13 Kinder, und berechnen Sie den Korrelationskoeffizienten zwischen Dauer des Medienkonsums und Aggressionslevel ohne Berücksichtigung des Geschlechts.

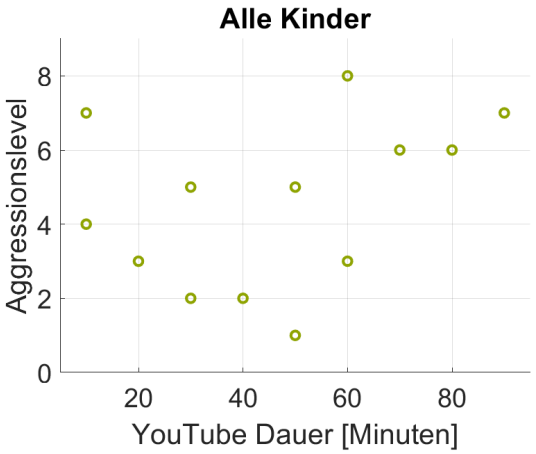
b) Zeichnen Sie nun für Jungen und Mädchen getrennt jeweils ein Streudiagramm und berechnen Sie für beide Geschlechter den Korrelationskoeffizienten.

c) Vergleichen Sie alle Ergebnisse und ziehen Sie Ihre Folgerungen.

LÖSUNG

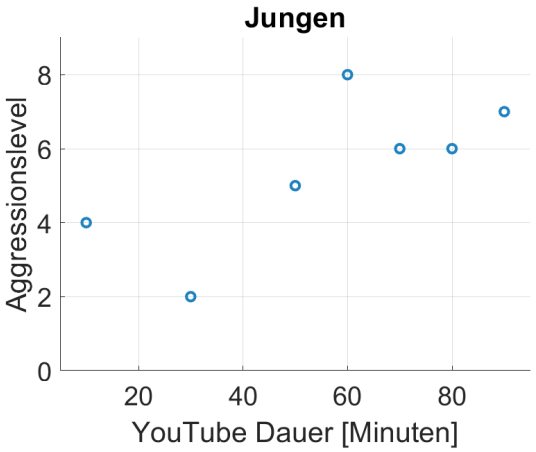
a) Alle Kinder:

- $\bar{x} = 46.154$
- $\bar{y} = 4.538$
- $r_{x,y} = 0.332$



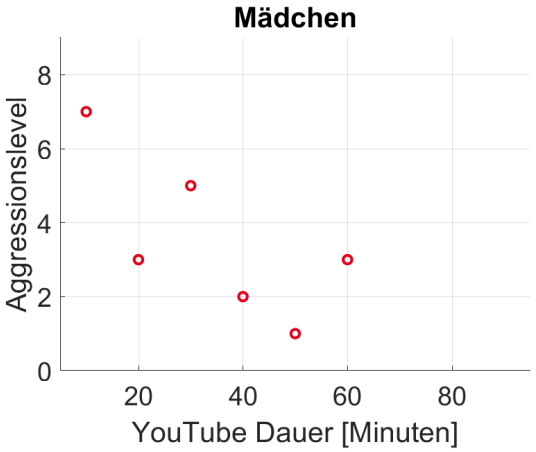
b) Jungen:

- $\bar{x} = 55.714$
- $\bar{y} = 5.429$
- $r_{x,y} = 0.722$



Mädchen:

- $\bar{x} = 35$
- $\bar{y} = 3.5$
- $r_{x,y} = -0.715$



c) Betrachtet man alle Kinder auf einmal, so lässt sich eine schwache positive, aber nicht sehr deutliche (siehe Bild) Korrelation feststellen.

Nach Geschlechtern getrennt zeigen die Ergebnisse jedoch, dass die Aggressivität bei Jungen mit der Dauer des Fernsehkonsums zunimmt, während sie bei Mädchen erkennbar abnimmt. weiterhin sind sowohl Dauer des Medienkonsums als auch Aggressionslevel im Mittel bei den Jungen deutlich höher als bei den Mädchen. Die beiden entgegengesetzten Wirkungen mitteln sich bei der Untersuchung beider Geschlechter zusammen heraus, sodass kaum eine Wirkung erkennbar ist.