Klausur im SS 22, 05.07.2022

Stochastik für Informatik Master

Prof. Dr. Barbara Staehle, HTWG Konstanz

Bearbeitungszeit: 90 Minuten

Hinweise:

- **Falls Sie für die Aufgaben alle Punkte haben wollen, begründen Sie Ihre Antworten. Stellen Sie den Lösungsweg nachvollziehbar dar, oder geben Sie an, welches Tool Sie verwendet haben.**
- Runden Sie alle Ergebnisse auf **mindestens 3 nicht-Null-Stellen** hinter dem Komma oder stellen Sie Ergebnisse als Bruch exakt dar.
- Lösen Sie, sofern möglich, die Aufgaben auf dem Angabenblatt.
- **Die Klausur enthält mehr Aufgaben, als Sie in der Bearbeitungszeit lösen können. Wählen Sie klug, welche Aufgaben Sie lösen!** Sie müssen weder zum Bestehen noch für eine sehr gute Note alle Aufgaben korrekt bearbeiten. Zum Bestehen reichen ca. **55 Punkte**, eine sehr gute Note gibt es **ab ca. 100** Punkten.

Name: _____

Matrikelnummer: _____

Note: _____

Aufgabe	1	2	3	4	5	Σ
Punkte	20	38	26	31	25	140
Erreicht						

AUFGABE 1, 20 PUNKTE
WAHR ODER FALSCH?

Sind folgenden Aussagen wahr oder falsch? Begründen Sie Ihre Entscheidung (kurz).

Punktvergabe: w/f richtig: 1 Punkt; w/f richtig und Begründung sinnvoll: 2 Punkte

Aussage	wahr	falsch	kurze Begründung
(a) Keine Dichtefunktion wird jemals den Wert -1000 annehmen.	☐	☐	
(b) Für eine beliebige Zufallsvariable X gilt $P(X \geq 5) = 1 - P(X \leq 4)$.	☐	☐	
(c) Für alle Ereignisse A, B gilt $P(A \mid B) = P(A \cap B)$.	☐	☐	
(d) Die Schätzfunktion eines Parameters ist unabhängig von einer konkreten Stichprobe, der konkrete Schätzwert fällt für verschiedene Stichproben unterschiedlich aus.	☐	☐	
(e) Für eine Zufallsvariable X mit Erwartungswert μ_X und Varianz σ_X^2 gilt $\sigma_X^2 = \mathrm{E}(X^2) - \mu_X^2$.	☐	☐	
(f) Sie lesen, dass das durchschnittlich Einkommen eines Zürichers bei 7820 Franken liegt. Das heißt, die eine Hälfte der Bevölkerung verdient mehr, die andere weniger als diese Summe.	☐	☐	
(g) Violinenplots kombinieren Boxplots und Scatter Plots	☐	☐	
(h) Skewness und Kurtosis beschreiben die empirische Schiefe und Wölbung einer Häufigkeitsverteilung.	☐	☐	
(i) Die Normalverteilung ist für die Stochastik extrem wichtig, weil sich (für ausreichend große Zahlen) jede andere Verteilung durch eine geeignete Normalverteilung annähern lässt.	☐	☐	
(j) Der Alters-Median der Hörer:innen des Podcasts "Hobbylos" liegt bei 23. Das heißt, dass eine:e typische Hobbylos-Hörer:in 23 Jahre alt ist.	☐	☐	

AUFGABE 2, 38 PUNKTE
STATISTIK

"Harry Potter" ist eine Serie von 7 Jugendromanen der Schriftstellerin Joanne K. Rowling. Erzählt wird die Geschichte von Harry Potter, Schüler des britischen Zaubererinternats Hogwarts, seinen Freunden und Gegenspielern. Die Buchreihe wurde in 8 Filmen umgesetzt. Ein paar Statistiken zu den Büchern (Seitenanzahl entspricht der britische Hardcover-Ausgabe) und Filmen sind in folgender Tabelle zusammengefasst.

Hinweis: Die Anzahl der Seiten für die Filme 7 und 8 wurde als die Hälfte der Seiten von Buch Nr. 7 berechnet. Bewertung des Filmes in Rotten Tomatoes: minimal 0%, maximal 100%

Film Nr.	1	2	3	4	5	6	7	8
Seitenzahl des Buches (S)	309	341	435	734	870	652	380	380
Filmbudget [Millionen \$] (B)	125	100	130	150	150	250	250	250
Einspielergebnis [Millionen \$] (E)	1001	880	797	897	942	934	978	1342
Rotten Tomatoes [%] (R)	81	83	90	88	78	83	77	96

2.1 UNIVARIATE STATISTIK

Berechnen Sie **für Filmbudget B (Zeile 2 der Tabelle)** die folgenden Größen.

(a) (2 Punkte) Modalwert

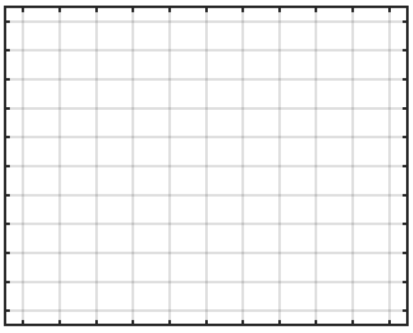
(b) (2 Punkte) Arithmetisches Mittel

(c) (2 Punkte) 95%-Quantil

(d) (2 Punkte) empirische Standardabweichung

(e) (3 Punkte) Interquartilabstand

(f) (4 Punkte) Skizzieren Sie die Verteilung der absoluten Häufigkeiten für das Filmbudget B. Beschriften Sie die Achsen korrekt!



(g) (2 Punkte) Nennen Sie zwei Eigenschaften der Häufigkeitsverteilung der Stichprobe B. Begründen Sie Ihre Meinung.

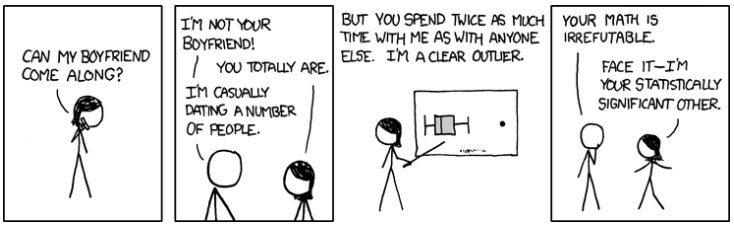
Verwenden Sie erwartungstreue, konsistente Schätzfunktionen, um basierend auf der obigen Stichprobe, Schätzwerte für das Budget eines Harry Potter Filmes zu berechnen für

(h) (2 Punkte) den wahren Mittelwert μ_B

(i) (2 Punkte) die wahre Varianz σ_B^2

(j) (2 Punkte) Das 90%-Konfidenzintervall für den wahren Erwartungswert des Einspielergebnisses eines Harry Potter Films berechnet sich zu $[133.069; 218.181]$. Was sagt dieses Intervall aus?

(k) (3 Punkte) Weshalb beweist der in folgendem Comic gezeigten Boxplot tatsächlich, dass die Person ohne Haare der feste Freund der Person mit langen Haaren ist?



2.2 Multivariate Statistik

Zur Erinnerung:

Film Nr.	1	2	3	4	5	6	7	8
Seitenzahl des Buches (S)	309	341	435	734	870	652	380	380
Filmbudget [Millionen \$] (B)	125	100	130	150	150	250	250	250
Einspielergebnis [Millionen \$] (E)	1001	880	797	897	942	934	978	1342
Rotten Tomatoes [%] (R)	81	83	90	88	78	83	77	96

(a) (6 Punkte) Analysieren Sie den Zusammenhang zwischen der Seitenanzahl des Buches, dem Budget und dem Einspielergebnis des Films und der Bewertung des Films in Rotten Tomatoes. Geben Sie hierzu in der untenstehende Tabelle, in der schon die jeweiligen empirischen Korrelationskoeffizienten (emp. KK) dargestellt sind, den Buchstaben des Scatterplots an, welcher zu dieser Kombination gehört.
Begründen Sie Ihre Entscheidung **kurz**!

Zusammenhang	emp. KK	Scatterplot	kurze Begründung
Seitenanzahl S und Tomatoes T	$r_{S,T} =$ -0.185		
Budget B und Tomatoes T	$r_{B,T} =$ 0.106		
Einspielergebnis E und Tomatoes T	$r_{E,T} =$ 0.447		
Budget B und und Einspielergebnis E	$r_{B,E} =$ 0.571		

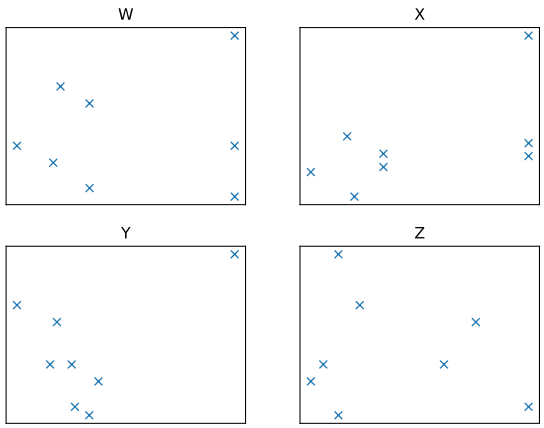


Abbildung 1: Welcher Scatterplot entspricht welchem Zusammenhang?

(b) (3 Punkte) Basierende auf den Zahlen und Ihren Erkenntnissen - was beeinflusst den Erfolg eines Harry Potter Filmes (gemessen am Einspielergebnis und der Bewertung) positiv oder negativ? Begründen Sie Ihre Meinung!

(c) (3 Punkte) Im Rahmen Ihrer weiteren Untersuchungen des Phänomens "Harry Potter" möchten Sie für alle Filme den Zusammenhang zwischen zwei anderen Merkmalen X und Y untersuchen. Für diese Analyse berechnen Sie folgende Kennwerte:

Kennwert	Wert
$\bar{x}$	54.26
$\bar{y}$	47.83
s_x	16.76
s_y	26.93
$r_{x,y}$	-0.06

Reichen diese Zahlen schon aus, um einen Zusammenhang zwischen X und Y zu erkennen (wenn ja, welchen)? Oder müssen Sie noch weitere Methoden anwenden (wenn ja welche)?

AUFGABE 3, 26 PUNKTE
WAHRSCHEINLICHKEITSRECHNUNG

3.1 Professor Snape unterrichtet Harry und seine Freunde im Fach Zaubertränke. Heute stellt er ihnen folgende Hausaufgabe:

Zaubertränke haben verschiedene Farben. Im Schullabor von Hogwarts befinden sich jedoch nur Zaubertränke, welch alle entweder rot, blau oder (XOR) grün sind. Weiterhin ist Zucker eine beliebte Zutat für Zaubertränke, welche auch die Farbe beeinflusst. Daher ist bekannt, dass

- 30% der Zaubertränke, welche Zucker enthalten, rot und 50% blau sind,
- 80% Zaubertränke, welche keinen Zucker enthalten, rot und 10% blau sind
- und insgesamt 16% aller Zaubertränke grün sind.

Hinweis: Verwenden Sie zur Modellierung des Szenarios die folgenden Ereignisse:

- R, B, G: ein Zaubertrank ist rot, blau, oder grün
- Z ein Zaubertrank enthält Zucker

(a) (5 Punkte) Modellieren Sie das beschriebene Szenario z.B. durch einen Wahrscheinlichkeitsbaum oder mit Hilfe einer Stichpunktliste. Geben Sie alle aus dem Text ableitbaren Wahrscheinlichkeiten der beschriebenen Ereignisse und ihrer jeweiligen Gegenereignisse an.

(b) (4 Punkte) Wie groß ist der Anteil der Zaubertränke, die Zucker enthalten?

(c) (2 Punkte) Wie groß ist der Anteil der blauen Zaubertränke?

(d) (3 Punkte) Mit welcher Wahrscheinlichkeit enthält ein blauer Zaubertrank Zucker?

(e) (2 Punkte) Sind die Ereignisse Z und B unabhängig? Begründen Sie Ihre Meinung.

3.2 Die URL eines YouTube-Videos (z.B. https://www.youtube.com/watch?v=gocwRvLhDf8) enthält dessen eindeutige **Video-ID** (in diesem Fall "gocwRvLhDf8").

Jede dieser Video-IDs besteht aus **11** Zeichen, welche jeweils ein Groß- oder ein Kleinbuchstabe ([a-zA-Z]), eine Ziffer ([0-9]), ein Bindestrich (-), oder ein Unterstrich (_) sein, und die mehrfach vorkommen dürfen.

Verwenden Sie dieses Modell für die folgenden Berechnungen:

(a) (2 Punkte) Wie viele mögliche Video-IDs gibt es?

(b) (2 Punkte) Mit welcher Wahrscheinlichkeit beginnt eine zufällig ausgewählte Video-ID mit den Buchstaben "HTWG"?

(c) (2 Punkte) Mit welcher Wahrscheinlichkeit besteht eine zufällig ausgewählte Video-ID nur aus Groß- und Kleinbuchstaben?

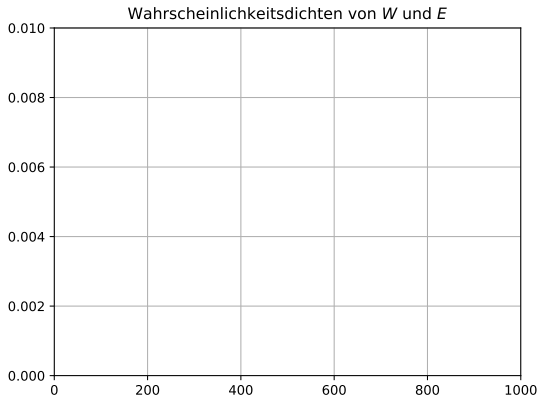
(d) (4 Punkte) YouTube gibt es seit 17 Jahren. Nehmen wir an, es wären bis zum heutigen Tag genau 17 Jahre. Wenn jeder der (vereinfacht) 7×10^9 Bewohner der Erde vor genau 17 Jahren angefangen hätte, täglich 1000 Videos hochzuladen (und damit täglich 1000 Video-IDs zu verbrauchen), wie lange denken Sie, würden die Video-IDs für dieses Verhalten (7×10^9 Menschen laden täglich 1000 neue Videos hoch) dann noch ungefähr ausreichen?
Schätzen Sie diese Zahl ab (und begründen Sie Ihre Schätzung) oder rechnen Sie diese Zahl überschlagsmäßig aus.

AUFGABE 4, 31 PUNKTE
STETIGE ZUFALLSVARIABLEN

Um die Klausurenphase etwas aufzuheitern, stellt der ASTA eine „lustige“ Getränkemaschine im Hof der HTWG auf. Diese gibt eisgekühltes Wasser und Eiskaffee aus und ist deshalb lustig, weil ihre Arbeitsweise mit Hilfe der folgenden kontinuierlichen, unabhängigen Zufallsvariablen beschrieben werden kann:

4.1
- W: Menge des ausgegebenen Wassers in ml ist normalverteilt mit Erwartungswert 700 und Standardabweichung 50.
- E: Menge des ausgegebenen Eiskaffees in ml ist normalverteilt mit Erwartungswert 500 und Standardabweichung 100.

(a) (4 Punkte) Skizzieren Sie die Wahrscheinlichkeitsdichten von W und E, f_W und f_E in untenstehendes Diagramm.
Wichtig:
- Ihre Skizze muss nicht exakt sein, aber den eventuellen vorhandenen Unterschied zwischen f_W und f_E darstellen.
- Beschriften Sie die Achsen korrekt.



(b) (2 Punkte) Mit welcher Wahrscheinlichkeit werden weniger als 650 ml Wasser ausgegeben?

(c) (2 Punkte) Schätzen Sie ab, außerhalb welches Intervalls die Ausgabemenge von Wasser nur in ungefähr 3 von 1000 Fällen liegt.

(d) (4 Punkte) In welchem, symmetrisch um den Erwartungswert gelegenen Intervall, liegt die Ausgabemenge von Eiskaffee in 90% der Fälle?

(e) (4 Punkte) Alice ist besonders durstig, daher holt sie sich sowohl ein Wasser, als auch einen Eiskaffee. Mit welcher Wahrscheinlichkeit erhält sie somit insgesamt mehr als einen Liter Flüssigkeit?

4.2 Die Getränkemaschine gibt in jedes Getränk Eiswürfel, welche eine quadratische Grundfläche mit zufälliger Seitenlänge, sowie eine zufällige Höhe haben, gegeben durch die Zufallsvariablen X und Y. Die gemeinsame Dichtefunktion gegeben ist als

$$f_{X,Y}(x,y) = \begin{cases} 0.1 & 1 \leq x \leq 3;\ \ 1 \leq y \leq 6 \\ 0 & \text{sonst.} \end{cases}$$

Begründen Sie (z.B. durch eine Rechnung), warum Sie aus diesen Funktionen ableiten können dass folgende Berechnungen bzw. Aussagen gültig sind:

(a) (3 Punkte) $f_X(x) = 0.5$

(b) (3 Punkte) $f_Y(y) = 0.2$

(c) (2 Punkte) X und Y sind unabhängig.

Bearbeiten Sie auch folgende weitere Aufgaben (siehe auch nächste Seite!

(d) (2 Punkte) Sind X und Y auch unkorreliert? Begründen Sie Ihre Meinung.

(e) (3 Punkte) Berechnen Sie den Erwartungswert der Seitenlänge der Eiswürfel, $E(X)$.

(f) (2 Punkte) Berechnen Sie die Wahrscheinlichkeit, dafür, dass X genau den Wert 1.5 annimmt.

AUFGABE 5, 25 PUNKTE
DISKRETE ZUFALLSVARIABLEN

5.1 Captain James Kirk, Kapitän des Raumschiffes Enterprise hat folgendes Problem: Die Auroraseuche wurde auf der Enterprise eingeschleppt und konnte sich dort unkontrolliert verbreiten. Die Auroraseuche ist eine Krankheit, deren auffälligstes Symptom Veränderungen der Hautfarbe der erkrankten Person ist. Diese wird zunächst grün, dann blau und zuletzt rot. Unbehandelt kann auf diese letzte Phase sogar der Tod folgen.

Die Auroraseuche auf der Enterprise weist eine **Prävalenz** von 0.005 auf (mit der Wahrscheinlichkeit 0.005 ist eine zufällig ausgewählte Person mit der Auroraseuche infiziert).

Das Leben auf der Enterprise geht aber weiter, daher ist der dortige Club nach einem längeren Lockdown wieder offen. Commander Spock hätte eigentlich Lust, dort zusammen mit Lieutenant Uhura tanzen zu gehen, ist sich aber nicht sicher, ob er das Risiko eingehen und mit $N = 100$ Personen zusammen in einem Club tanzen soll. Daher rechnet er zwei Szenarien durch:

- **Szenario 1**: Es gibt keine Zugangskontrollen, jede Person die will, darf in den Club. Es ist also jede Person mit einer Wahrscheinlichkeit von $p_1 = 0.005$ infiziert.
- **Szenario 2**: Nur Personen, die ein Zertifikat über einen negativen Schnelltest vorweisen können, dürfen in den Club. Nehmen wir an, für alle Personen gilt die gleiche Prävalenz p_1 und alle werden mit dem gleichen Schnelltest getestet, der eine **Sensitivität** (das Ergebnis einer infizierte Person ist positiv) von 0.85 und eine **Spezifität** (das Ergebnis einer nicht-infizierten Person ist negativ) von 0.99 hat. Es sind also nur noch die Personen, die mit einem falsch-negativen Testergebnis den Club besuchen, mit einer Wahrscheinlichkeit von $p_2 \leq p_1$ mit der Auroraseuche infiziert.

(a) (3 Punkte) Berechnen Sie die Wahrscheinlichkeit p_2, mit der eine im Club tanzende Person in Szenario 2 mit der Seuche infiziert ist.

(b) (2 Punkte) Geben Sie die Verteilung der Zufallsvariablen X_1 und X_2 an (wie und mit welchen Parametern). X_1 beschreibt die Anzahl der infizierten Club-Besucher für **Szenario 1**, X_2 beschreibt die Anzahl für **Szenario 2**.

(c) (2 Punkte) Geben Sie die Erwartungswerte der Zufallsvariablen X_1 und X_2 an.

(d) (3 Punkte) Geben Sie für beide Szenarien die Wahrscheinlichkeiten an, dass keine im Club tanzende Person mit der Auroraseuche infiziert ist.

(e) (3 Punkte) Geben Sie für beide Szenarien den Wert an, unter dem die Anzahl der infizierten Personen mit einer Wahrscheinlichkeit von 99% liegt.

(f) (3 Punkte) Wenn Sie an Spocks Stelle wären - gibt es ein Szenario in welchem Sie mit zum Tanzen gehen würden? Begründen Sie Ihre Meinung.

(g) (3 Punkte) Wäre es zulässig, wenn Spock die Wahrscheinlichkeit für die Anzahl der Male, die er tanzen gehen kann, bis er sich doch infiziert mit Hilfe der geometrischen Verteilung berechnet? Begründen Sie Ihre Meinung.

5.2 Beweisen Sie, dass für eine beliege Zufallsvariable X, die Bernoulli-verteilt mit Parameter $0 < p < 1$ ist ($X \sim Ber(p)$), gilt

(a) (2 Punkte) $\mathrm{E}(X) = p$

(b) (3 Punkte) $\mathrm{Var}(X) = p(1-p)$

(c) (1 Punkt) Wie kann man den Erwartungswert einer binomialverteilten Zufallsvariable $Y \sim Bin(n,p)$, $E(Y) = np$ aus dem Erwartungswert einer Bernoulli-verteilten Zufallsvariable X ableiten?