Klausur im SS 23, 11.07.2023

Stochastik für MSI

Prof. Dr. Barbara Staehle, HTWG Konstanz

Bearbeitungszeit: 90 Minuten

Hinweise:

- **Erlaubt und empfohlen:** Nutzung Ihrer eigenen Intelligenz.
  Verboten: Nutzung fremder Intelligenzen (echte und künstliche).
- **Falls Sie auch für falsche Lösungen Teil-Punkte haben wollen, begründen Sie Ihre Antworten und stellen Sie den Lösungsweg nachvollziehbar dar.**
- Runden Sie alle Ergebnisse auf **mindestens 2 nicht-Null-Stellen** hinter dem Komma oder stellen Sie Ergebnisse als Bruch exakt dar.
- Lösen Sie, sofern möglich, die Aufgaben auf dem Angabenblatt.
- **Die Klausur enthält mehr Aufgaben, als Sie in der Bearbeitungszeit lösen können. Wählen Sie klug, welche Aufgaben Sie lösen!** Sie müssen weder zum Bestehen noch für eine sehr gute Note alle Aufgaben korrekt bearbeiten. Zum Bestehen reichen ca. **65 Punkte**, eine sehr gute Note gibt es **ab ca. 115** Punkten.

Name: _____

Matrikelnummer: _____

Note: _____

Aufgabe	1	2	3	4	5	Σ
Punkte	20	39	23	32	26	140
Erreicht						

AUFGABE 1, 20 PUNKTE
WAHR ODER FALSCH?

Sind folgenden Aussagen wahr oder falsch? Begründen Sie Ihre Entscheidung (kurz).

Punktvergabe: w/f richtig: 1 Punkt; w/f richtig und Begründung sinnvoll: 2 Punkte

Aussage	wahr	falsch	kurze Begründung
(a) Die Normalverteilung ist für die Stochastik extrem wichtig, weil sich im Wesentlichen jede andere Verteilung durch eine geeignete Normalverteilung annähern lässt.	☐	☐	
(b) Eine Bernoulli-Kette der Länge 100 besteht aus 100 unabhängig von einander unter identischen Bedingungen ausgeführten Bernoulli-Experimenten.	☐	☐	
(c) Die Summe zweier exponentialverteilter Zufallsvariablen ist wieder exponentialverteilt.	☐	☐	
(d) Diskrete Zufallsvariablen haben keine Verteilungsdichten, stetige Zufallsvariablen haben keine Verteilung, aber Verteilungsfunktionen haben sie beide.	☐	☐	
(e) Alle Werte, die eine beliebig verteilte Zufallsvariable X annimmt, liegen im Intervall $\mu_X \pm 3\sigma_X$.	☐	☐	
(f) Für alle Ereignisräume Ω und alle Ereignisse $A, B \subseteq \Omega$ gilt: $P(A\|B) < P(A)$.	☐	☐	
(g) Aus dem Gesetz der großen Zahlen folgt nicht, dass bei 6 Millionen W6-Würfel-Würfen genau 1 Million Mal die 5 vorkommt.	☐	☐	
(h) Eine gute Schätzfunktion ist entweder erwartungstreu oder konsistent.	☐	☐	
(i) Eine Stichprobe von nominalen Merkmalen lässt sich mit Hilfe der Normalverteilung approximieren.	☐	☐	
(j) Die Größe eines Konfidenzintervalls ist unabhängig von Stichprobengröße.	☐	☐	

AUFGABE 2, 39 PUNKTE
STATISTIK

Dr. Wu ist der Chefgenetiker des Jurrassic Parks, eines Vergnügungsparks, dessen Hauptattraktion geklonte, genetisch verbesserte Dinosaurier sind. Der Jurassic Park möchte als weitere Attraktion ein Dino-Rennen anbieten, daher arbeitet Dr. Wu daran, Dinosaurier mit großer Geschwindigkeit (V) zu klonen, deren Hunger (F, [kg Fleisch pro Tag]) nicht überhand nimmt.

Genetik ist in hohem Maße vom Zufall beeinflusst, daher simuliert Dr. Wu am Computer geklonte Dinosauriern mit zufällig erzeugter Größe in cm (G) und Agressionslevel (A) in %. Dr. Wu hat am Computer eine große Grundgesamtheit geklonter Dinosaurier entwerfen lassen. Aus dieser Grundgesamtheit untersucht er eine Stichprobe von 10 Dinosauriern deren Eigenschaften in folgender Tabelle zusammengefasst sind.

Dino Nr.	1	2	3	4	5	6	7	8	9	10
Geschwindigkeit [km/h] (V)	62	47	15	37	53	56	93	59	57	35
Fleischverbrauch [kg] (F)	13	11	8	8	9	12	14	9	27	11
Körpergröße [cm] (G)	302	308	238	203	243	308	328	297	315	211
Agressionslevel [%] (A)	37	55	55	42	50	50	55	42	55	51

2.1 UNIVARIATE STATISTIK

Analysieren Sie **die Geschwindigkeit der Dinosaurier V (Zeile 1 der Tabelle)**.

(a) (2 Punkte) Berechnen Sie das arithmetisches Mittel der Stichprobe

(b) (2 Punkte) Berechnen Sie den Median der Stichprobe

(c) (2 Punkte) Vergleichen Sie das arithmetisches Mittel und den Median der Stichprobe. Was können Sie aus diesem Vergleich schlussfolgern?

(d) (2 Punkte) Berechnen Sie das 75%-Quantil der Stichprobe

(e) (2 Punkte) Geben Sie an, wie Sie das 75%-Quantil mit Ihrem verwendeten Tool berechnen.

(f) (3 Punkte) Anna und Ben helfen Dr. Wu bei den Auswertungen. Anna berechnet die empirische Standardabweichung zu $s_v = 20.484$, Ben berechnet $s_v = 19.433$. Beide haben Python bzw. MATLAB verwendet und die Zahlen korrekt eingegeben. Welche Zahl ist die richtige? Woran kann es liegen, dass die beiden Zahlen unterschiedlich sind?

(g) (2 Punkte) Anna erhält von Dr. Wu den Auftrag, das 95% Konfidenzintervall für den wahren Erwartungswert der Geschwindigkeiten der Dinosaurier zu berechnen. Umkreisen Sie den richtigen Ansatz und begründen Sie Ihre Meinung.

1) $[\bar{v} - t_{10;0.975} \cdot \frac{s_v}{\sqrt{n}}; \bar{v} + t_{10;0.975} \cdot \frac{s_v}{\sqrt{n}}]$ 2) $[\bar{v} - t_{10;0.95} \cdot \frac{s_v}{\sqrt{n}}; \bar{v} + t_{9;0.95} \cdot \frac{s_v}{\sqrt{n}}]$
3) $[\bar{v} - z_{0.975} \cdot \frac{s_v}{\sqrt{n}}; \bar{v} + z_{0.975} \cdot \frac{s_v}{\sqrt{n}}]$ 4) $[\bar{v} - t_{9;0.975} \cdot \frac{s_v}{\sqrt{n}}; \bar{v} + t_{9;0.975} \cdot \frac{s_v}{\sqrt{n}}]$

(h) (2 Punkte) Mit Hilfe des korrekten Ansatzes berechnet Anna das 95%-Konfidenzintervall zu $[36.747; 66.053]$. Was sagt dieses Intervall aus? Wenn Sie an Dr. Wu's Stelle wären, wären Sie mit dem Konfidenzintervall zufrieden, und würden daraus wichtige Erkenntnisse für Ihre weiteren Versuche ableiten?

(i) Dr. Wu möchte die Parameter der zufällig erzeugten Dinosaurier vergleichen. Hierfür **normalisiert** er alle Werte und dividiert alle erhobenen Ausprägungen eines Merkmals durch den jeweiligen Mittelwert. Z.B. werden alle Geschwindigkeitswerte durch die mittlere Geschwindigkeit $\bar{v}$ dividiert. Dies führt zur in Abbildung 1 gezeigte Grafik. Die Bezeichnungen auf der X-Achse entsprechen den Bezeichnungen in der Tabelle.

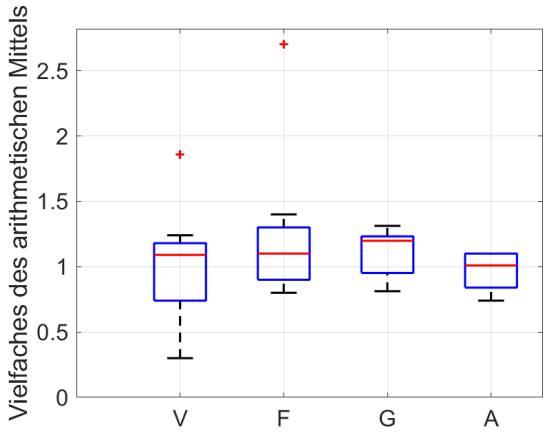


Abbildung 1: Normalisierte Werte der Stichprobe.

α) (2 Punkte) Wie heißt die in Abbildung 1 verwendete Darstellungsform? Welche Kennwerte kann man der Grafik entnehmen?

β) (3 Punkte) Welche Erkenntnisse kann Dr. Wu aus dieser Grafik ziehen? Was fällt auf, wenn man die verschiedenen Merkmale untereinander vergleicht?

2.2 Multivariate Statistik

Zur Erinnerung:

Dino Nr.	1	2	3	4	5	6	7	8	9	10
Geschwindigkeit [km/h] (V)	62	47	15	37	53	56	93	59	57	35
Fleischverbrauch [kg] (F)	13	11	8	8	9	12	14	9	27	11
Körpergröße [cm] (G)	302	308	238	203	243	308	328	297	315	211
Agressionslevel [%] (A)	37	55	55	42	50	50	55	42	55	51

(a) (9 Punkte) Analysieren Sie den Zusammenhang zwischen den Eigenschaften der Dinosaurier der Stichprobe. Streichen Sie hierzu in der untenstehende Tabelle für jede Paarung den **falschen** empirischen Korrelationskoeffizienten (emp. KK) durch und geben Sie den Buchstaben des Scatterplots an, welcher zu dieser Kombination gehört. Begründen Sie Ihre Entscheidung **kurz**!

Zusammenhang	emp. KK	Scatterplot	kurze Begründung
Größe G und Geschwindigkeit V	0.312 0.731		
Größe G und Fleischverbrauch F	-0.056 0.525		
Aggressionslevel A und Geschwindigkeit V	-0.056 0.525		
Aggressionslevel A und Fleischverbrauch F	0.312 0.731		

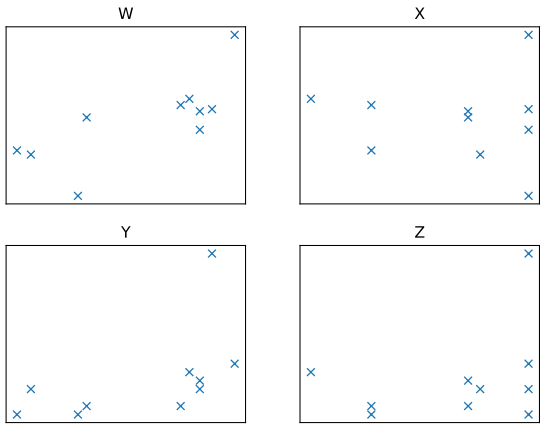


Abbildung 2: Welcher Scatterplot entspricht welchem Zusammenhang?

(b) (3 Punkte) Basierend auf Ihren Erkenntnissen - kann Dr. Wu möglichst schnelle Dinosaurier, die gleichzeitig möglichst wenig fressen erzeugen, indem er gezielt einen Parameter verändert? Falls ja wie? Falls nein, wieso? Begründen Sie Ihre Meinung!

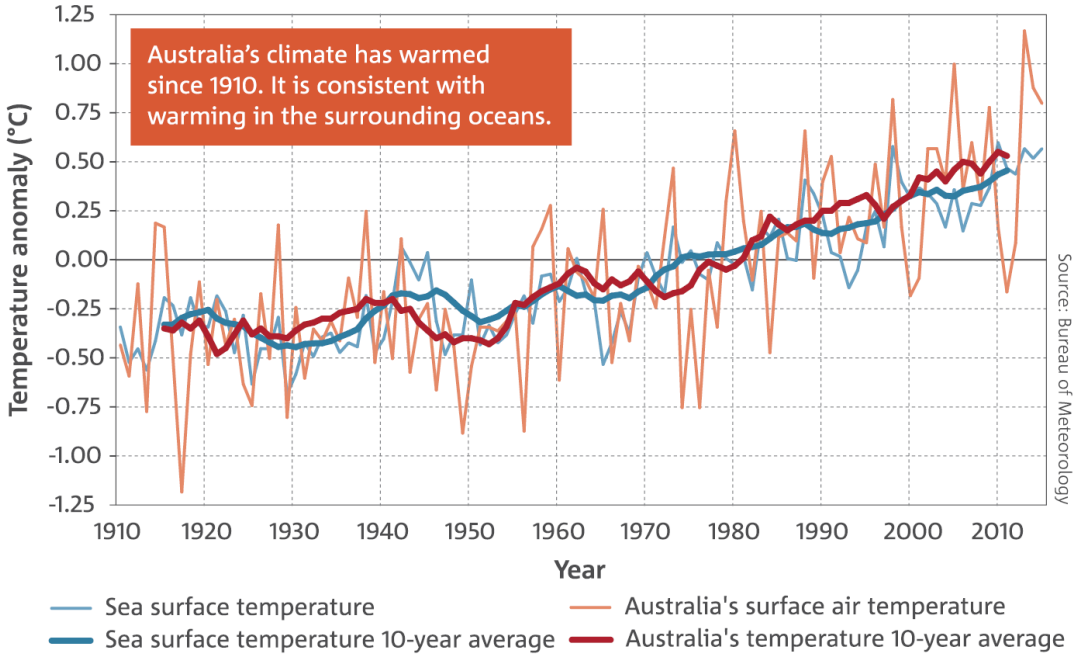


Abbildung 3: Anomalies in annual mean sea surface temperature, and temperature over land, in the Australian region. Anomalies are the departures from the 1961–90 standard averaging period. Sea surface temperature values are provided for a region around Australia (4–46 °S and 94–174 °E).

2.3 Zeitreihen

Betrachten Sie die obige Grafik und beantworten Sie folgende Fragen:

(a) (3 Punkte) Warum sind die dicken Linien ("10-year average") in Abbildung 3 weniger zappelnd als die dünneren Linien gleicher Farbe? Wie berechnen sich die Y-Werte der dicken Linien und wieso sind diese nicht bis zu den Rändern gezeichnet?

(b) (2 Punkte) Anna findet, dass diese Kurve die Aussage, "Australia's climate has warmed since 1910. The oceans surrounding Australia have also warmed." **nicht** unterstreicht. Erstens, seien die Veränderungen nur minimal und zweitens, enthielte jede Zeitreihe periodische Schwankungen und Rauschanteile in Form von zufälligen Einflüssen. Anna ist der Meinung, diese Daten zeigten gar nichts, es könne gut sein, dass die Temperatur in den nächsten Jahren wieder zufällig nach unten schwankt.
Was denken Sie? Schließen Sie sich der Meinung von Alice an, oder unterstützen Sie die erwähnte Aussage? Begründen Sie Ihre Meinung.

AUFGABE 3, 23 PUNKTE
WAHRSCHEINLICHKEITSRECHNUNG

3.1 Im Jurassic Park gibt es auch ein Streichelgehege. Die Streichel-Dinos beißen die Besucher leider manchmal, treten sie oder bespucken sie mit Gift. Auch gibt es im Jurassic Park noch sonstige Verletzungsmöglichkeiten, weshalb dieser eine Krankenstation unterhält. Die Krankenstation möchte ihre Behandlungsmethoden optimieren, daher werden Sie als Expert:in um Rat gebeten. Nach einer Auswertung der Akten stellen Sie fest:

- 75% der behandelten Verletzungen werden durch fleischfressende Dinosaurier verursacht, 15% durch pflanzenfressende Dinosaurier, alle anderen Verletzungen fallen in die Kategorie “sonstige Gründe”.
- die Verletzungen sind alle entweder lebensgefährlich oder nicht lebensgefährlich.
- 95% der Verletzungen, welche von einem Fleischfresser verursacht wurden, sind lebensgefährlich,
- 80% der Verletzungen, welche von einem Pflanzenfresser verursacht wurden, sind nicht lebensgefährlich und
- 99% der Verletzungen, die einen sonstigen Grund haben, sind nicht lebensgefährlich.

Hinweis: Verwenden Sie zur Modellierung des Szenarios die folgenden Ereignisse und Gegenereignisse:

- F, P, S: eine Verletzung wurde durch einen fleisch- oder einen pflanzenfressenden Dinosaurier verursacht oder hat sonstige Gründe
- L eine Verletzung ist lebensgefährlich

(a) (5 Punkte) Modellieren Sie das beschriebene Szenario z.B. durch einen Wahrscheinlichkeitsbaum oder durch eine Liste. Geben Sie alle aus dem Text ableitbaren Wahrscheinlichkeiten der beschriebenen Ereignisse und ihrer Gegenereignisse an.

(b) (3 Punkte) Wie groß ist der Anteil der lebensgefährlichen Verletzungen?

(c) (2 Punkte) Mit welcher Wahrscheinlichkeit ist eine auftretende Verletzung lebensgefährlich und von einem Fleischfresser verursacht?

(d) (3 Punkte) Mit welcher Wahrscheinlichkeit wurde eine Verletzung, von der man weiß, dass sie lebensgefährlich ist, von einem Fleischfresser verursacht?

(e) (3 Punkte) Mit welcher Wahrscheinlichkeit wurde eine Verletzung, von der man weiß, dass sie lebensgefährlich ist, **nicht** von einem Fleischfresser, sondern von einem Pflanzenfresser oder durch sonstige Gründe, verursacht?

(f) (3 Punkte) Die Parkleitung möchte das Streichel-Gehege beibehalten und insbesondere auch die Fleischfresser dort. Daher argumentiert sie, dass die Ereignisse F und L unabhängig seinen, dass also lebensgefährliche Verletzung auch nicht häufiger von Fleischfressern verursacht werden. Schließen Sie sich diesem Urteil an? Begründen Sie Ihre Meinung.

3.2 (4 Punkte) Beweisen Sie den Satz von Bayes für $n = 2$, bzw. leiten Sie diesen her oder begründen Sie ihn:

Gegeben ist eine beliebige Partition E_1, E_2 eines Ereignisraums Ω und ein beliebiges Ereignis $A \subseteq \Omega$. Die Wahrscheinlichkeit, dass eines der Ereignisse E_j, $j \in \{1, 2\}$ unter der Bedingung von A eintritt, ist

$$P(E_j|A) = \frac{P(E_j)P(A|Ej)}{P(E_1)P(A|E_1) + P(E_2)P(A|E_2)}$$

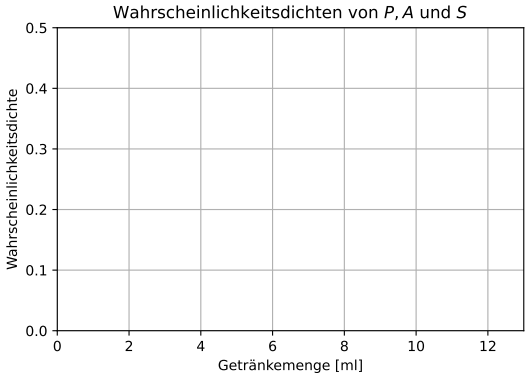
AUFGABE 4, 32 PUNKTE
STETIGE ZUFALLSVARIABLEN

Nach Feierabend sitzen Dr. Wu, Anna, Ben und Celembrimbor noch in der HTWG Strandbar auf einen Aperol Spritz zusammen, ein Getränk, das aus Prosecco, Aperol und Sodawasser besteht. Saurons dunkle Machenschaften verursachen, dass die Gäste alle verschieden befüllte Aperol Spritz Gläser erhalten, deren Bestandteile (in cl) mit Hilfe der folgenden kontinuierlichen, unabhängigen Zufallsvariablen beschrieben werden können:

- P: Menge des im Glas enthaltenen Proseccos ist normalverteilt mit Erwartungswert 9 und Standardabweichung 2.
- A: Menge des im Glas enthaltenen Aperols ist gleichverteilt zwischen 1 und 11.
- S:Menge des im Glas enthaltenen Sodawassers ist gegeben durch die Dichtefunktion

$$f_S(x) = \begin{cases} 0 & \text{für } x < 1 \\ \frac{1}{20}(2x-1) & \text{für } 1 \le x \le 5 \\ 0 & \text{für } x > 5. \end{cases}$$

4.1 (a) (6 Punkte) Skizzieren Sie die Wahrscheinlichkeitsdichtefunktionen von P,A und S, f_A, f_P und f_S in untenstehendes Diagramm. Ihre Skizze muss nicht exakt sein, aber den eventuellen vorhandenen Unterschied zwischen f_A, f_P und f_S darstellen.



(b) (3 Punkte) Bestimmen Sie die Verteilungsfunktion $F_S(x)$ von S.

(c) (2 Punkte) Anna berechnet den Erwartungswert der Menge des im Glas enthaltenen Sodawassers, $\mathrm{E}(S)$, wie folgt:

$$\begin{aligned} \mathrm{E}(S) &= \int_1^5 \tfrac{1}{20} \cdot (2t^2 - t)\, \mathrm{d}\, t = \tfrac{1}{20} \cdot \left[\tfrac{2}{3}t^3 - \tfrac{1}{2}t^2\right]_1^5 \\ &= \tfrac{1}{20} \cdot (\tfrac{250}{3} - \tfrac{25}{2} - \tfrac{2}{3} + \tfrac{1}{2}) = \tfrac{1}{20} \cdot \tfrac{500-75-4+3}{6} = \tfrac{1}{20} \cdot \tfrac{424}{6} = \tfrac{53}{15} = 3.533. \end{aligned}$$

Ist diese Rechnung korrekt oder falsch? Begründen Sie Ihre Meinung.

(d) (2 Punkte) Mit welcher Wahrscheinlichkeit enthält ein Glas genau 2 cl Sodawasser?

(e) (4 Punkte) In welchem, symmetrisch um den Erwartungswert gelegenen Intervall, liegt Menge des im Glas enthaltenen Proseccos in 50% der Fälle?

(f) (4 Punkte) Welche Menge an Prosecco wird in 99% aller Fälle nicht unterschritten? Geben Sie zusätzlich an, wie Sie diese Zahl mit Ihrem verwendeten Tool berechnen.

(g) (2 Punkte) Bestimmen Sie den Erwartungswert der Menge des im Glas enthaltenen Aperols, E(A).

(h) Ben denkt darüber nach, wie voll die Gläser typischerweise sind. Daher definiert er die Zufallsvariable G, für die in einem Aperol Spritz-Glas enthaltende Menge als

$$G = P + A + S.$$

Falls dies **einfach** möglich ist, bestimmen Sie die folgenden Zahlen. Falls dies nicht einfach sein sollte, rechnen Sie diese nicht aus, aber begründen Sie Ihre Meinung!

α) (2 Punkte) den Erwartungswert der Gesamtfüllmenge G, $E(G)$

β) (2 Punkte) die Wahrscheinlichkeit dass insgesamt weniger als 15 cl Aperol Spritz im Glas sind.

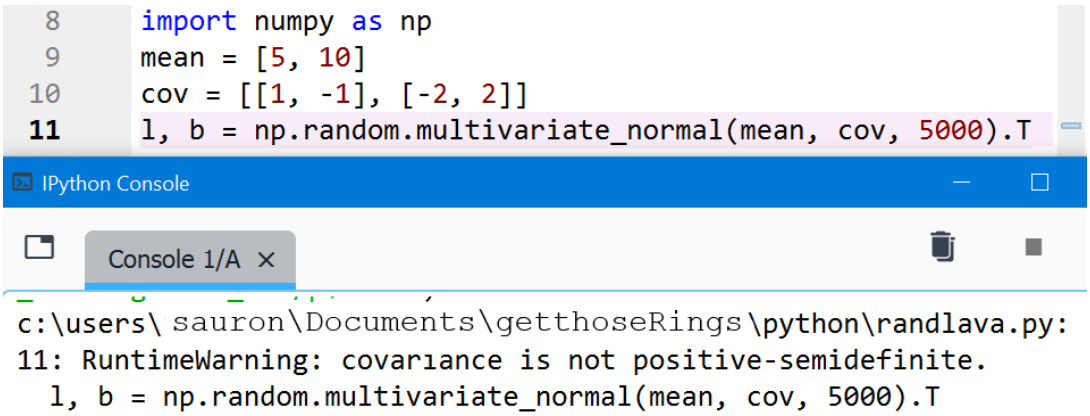


Abbildung 4: Saurons Problem´

4.2 Sauron möchte 5000 Lavawürfel auf die Strandbar fallen lassen. Er möchte die Länge (l) und Breite (b) der Grundfläche dieser Würfel in Python als korrelierte Zufallsvariablen erstellen. Seinen verwendeten Code sehen sie in Abbildung 4.

(a) (3 Punkte) Erklären Sie Saurons Code: Was enthalten die Parameter `mean` und `cov` und was liefert die in Zeile 11 aufgerufene Funktion zurück?

(b) (2 Punkte) Was hat die Runtime Warning zu bedeuten und wieso entsteht diese? Schlagen Sie vor, wie Sauron den Code ändern könnte, so dass diese nicht mehr auftritt.

AUFGABE 5, 26 PUNKTE
DISKRETE ZUFALLSVARIABLEN

Francesca, und Hamit studieren MSI und haben für ihren Studiengang einen Server aufgesetzt, auf dem sie Lernvideos zu den aktuellen Vorlesungen teilen. In letzter Zeit hat der Server immer mal wieder Performance-Probleme, denen die beiden nun auf den Grund gehen möchten. Da sie nicht sicher sind, wo der Fehler liegt, beschreibt jeder von ihnen einen Teilaspekt des Systems mit Hilfe von Zufallsvariablen.

5.1 Hamit hat den Verdacht, dass zu viele hintereinander abgespielte Mathematik-Videos den Server zum Absturz bringen. Daher findet er heraus, dass von $N_0 = 1000$ auf dem Server gespeicherten Videos genau $N_1 = 450$ Stück Mathematik-Videos sind.

Hamit verwendet zur Beschreibung dieses Szenarios die folgenden Zufallsvariablen

- M: Anzahl der Mathematik-Videos in einer Session von 10 zufällig ausgewählten und betrachteten Videos
- W: Anzahl der Videos, die zufällig ausgewählt und abgespielt werden müssen, bis endlich ein Mathematik-Video kommt. Nehmen Sie für W vereinfachend an, dass der Server unendlich viele Lernvideos enthält.

(a) (4 Punkte) Geben Sie an, wie und mit welchen Parametern die Zufallsvariablen W und M verteilt sind. Geben Sie hierzu an, weshalb und wie M *eigentlich* verteilt ist, aber warum und durch welche einfachere Verteilung diese approximiert werden kann. Verwenden Sie im weiteren Verlauf der Aufgabe die *einfachere* Verteilung.

(b) (4 Punkte) Wie groß ist die Wahrscheinlichkeit, dass in einer Serie von 10 betrachteten Lernvideos mehr als 3 Mathematik-Videos sind? Geben Sie zusätzlich an, wie Sie diese Zahl mit Ihrem verwendeten Tool berechnen.

(c) (2 Punkte) Wie viele Videos müssen mindestens angesehen werden, bis mit Sicherheit (also einer Wahrscheinlichkeit von 100%) ein Mathematik-Video kommt?

5.2 Francesca konzentriert sich auf Video-Bewertungen, welche der Server auch bearbeiten muss. Vereinfacht können diese mit Hilfe folgender Zufallsvariablen beschrieben werden:

- A: die Anzahl der Bewertungen, die pro Stunde eintreffen, ist eine Poisson-verteilte Zufallsvariable mit Rate $\lambda_A = 5$.
- B: die für jedes Video vergebenen Bewertung ist gegeben durch ihre Verteilung

x	1	2	3	4	5
$P(B = x)$	0.1	0.1	0.2	0.2	0.4

(a) (3 Punkte) Berechnen Sie die Erwartungswerte von A und B.

(b) (2 Punkte) Mit welcher Wahrscheinlichkeit ist die Anzahl der Bewertungen, die pro Stunde auf dem Server eingehen, gleich 5?

(c) (2 Punkte) Mit welcher Wahrscheinlichkeit ist eine abgegebene Bewertung 3 oder besser?

5.3 Francesca hat die Theorie, dass die Höhe der Bewertung mit der Anzahl der Video zusammenhängt, die eine Person am Tag ansieht. Hierzu verwendet sie (zusätzlich zur bekannten Zufallsvariable B aus Aufgabe 5.2) die **diskrete** Zufallsvariable C, die Anzahl an gesehenen Videos modelliert. Sie findet heraus, dass die gemeinsame Verteilung von B und C gegeben ist durch

$P(c=i, B=j)$	$B=1$	$B=2$	$B=3$	$B=4$	$B=5$
$C=1$	0.1	0.05	0	0	0
$C=2$	0	0.05	0.1	0.05	0
$C=3$	0	0	0.1	0.15	0.4

(a) (2 Punkte) Geben Sie die Verteilung von C an.

(b) (3 Punkte) Kreisen Sie in untenstehender Tabelle jeweils die korrekten Werte an, welche B, C, sowie deren Beziehung untereinander charakterisieren.

Größe	Option 1	Option 2	Option 3
$\mathrm{E}(C)$	0.1	2.5	3
$\mathrm{E}(B \cdot C)$	25	-5	10.1
σ_B	17.57	-1.35	1.35
σ_C	0	0.74	-0.74
$\mathrm{Cov}(B,C)$	0.85	-9	0.001
$\rho_{B,C}$	0.05	0.85	-0.72

(c) (4 Punkte) Kreuzen Sie **zwei richtige** Aussagen an. Begründen Sie Ihre Entscheidung, aber bitte **nicht mit Hilfe einer langen Rechnung**!

a) B und C sind abhängig.
b) B und C sind unabhängig.
c) B und C sind unkorreliert.
d) B und C sind positiv korreliert.
e) B und C sind negativ korreliert.