Klausur im SS 24, 22.07.2024

Stochastik für MSI

Prof. Dr. Barbara Staehle, HTWG Konstanz

Bearbeitungszeit: 90 Minuten

Hinweise:

- **Erlaubt und empfohlen:** Nutzung Ihrer eigenen Intelligenz.
  Verboten: Nutzung fremder Intelligenzen (echte und künstliche).
- **Falls Sie auch für falsche Lösungen Teil-Punkte haben wollen, begründen Sie Ihre Antworten und stellen Sie den Lösungsweg nachvollziehbar dar.**
- Runden Sie alle Ergebnisse auf **mindestens 2 nicht-Null-Stellen** hinter dem Komma oder stellen Sie Ergebnisse als Bruch exakt dar.
- Lösen Sie, sofern möglich, die Aufgaben auf dem Angabenblatt.
- **Die Klausur enthält mehr Aufgaben, als Sie in der Bearbeitungszeit lösen können. Wählen Sie klug, welche Aufgaben Sie lösen!** Sie müssen weder zum Bestehen noch für eine sehr gute Note alle Aufgaben korrekt bearbeiten. Zum Bestehen reichen ca. **70 Punkte**, eine sehr gute Note gibt es **ab ca. 120** Punkten.

Name: _____

Matrikelnummer: _____

Note: _____

Aufgabe	1	2	3	4	5	Σ
Punkte	20	41	23	36	30	150
Erreicht						

AUFGABE 1, 20 PUNKTE
WAHR ODER FALSCH?

Sind folgenden Aussagen wahr oder falsch? Begründen Sie Ihre Entscheidung (kurz).

Punktvergabe: w/f richtig: 1 Punkt; w/f richtig und Begründung sinnvoll: 2 Punkte

Aussage	wahr	falsch	kurze Begründung
(a) Näherungsweise Berechnungen von Verteilungen sind heute irrelevant, da mit moderner Hardware immer alles exakt augerechnet werden kann.	☐	☐	
(b) Nur 3 von 1000 Werten der Realisierung der ZV $X \sim \mathrm{N}(100, 10)$ sind größer als 130 oder kleiner als 70.	☐	☐	
(c) Violinenplots kombinieren Boxplots und Scatter Plots	☐	☐	
(d) Viele, aber nicht alle Verteilungen können durch eine Normalverteilung mit geeigneten Parametern approximiert werden.	☐	☐	
(e) Für eine beliebige Zufallsvariable X gilt $P(X \geq 5) = 1 - P(X \leq 4)$.	☐	☐	
(f) Für alle Ereignisräume Ω und alle Ereignisse $A, B \subseteq \Omega$ gilt $P(A \cup B) = P(A) + P(B) - P(A \mid B) \cdot P(B)$.	☐	☐	
(g) Aus dem Gesetz der großen Zahlen folgt nicht, dass bei 6 Millionen W6-Würfel-Würfen genau 1 Million Mal die 5 vorkommt.	☐	☐	
(h) Für jede stetige Zufallsvariable X mit Dichte $f(x)$ und alle $a \in \mathbb{R}$ gilt $P(X = a) = f(a)$.	☐	☐	
(i) Für alle $p \in [0, 1]$ sind die p-Quantile der Student-t-Verteilung immer größer oder gleich den p-Quantilen der Standardnormalverteilung.	☐	☐	
(j) Der Korrelationskoeffizient zeigt die lineare Beziehungen zwischen zwei Datensätzen.	☐	☐	

AUFGABE 2, 41 PUNKTE
STATISTIK

Die, von den Warner Bros. Studios herausgebrachten, 8 Kinofilme über Harry Potter erzählen die Geschichte von Harry, Schüler der Zauberschule Hogwarts, seinen Freund:innen und Gegenspieler:innen. Die Warner Bros. Studios möchten 3 neue Harry Potter Filme drehen und haben Sie daher beauftragt, Erfolgsfaktoren der bisherigen Filme herauszufinden. Hierfür stehen Ihnen die Statistiken der folgenden Tabelle zur Verfügung.

Hinweis: Erfolg des Films E wird durch Platzierung auf der Liste der erfolgreichsten Filme angegeben, kleiner ist besser, maximal erfolgreich, das Ziel aller Filmstudios wäre $E = 1$.

Film Nr.	1	2	3	4	5	6	7	8
Filmbudget [Millionen \$] (B)	125	100	130	150	150	250	125	125
Filmlänge [min] (L)	152	161	142	157	138	153	146	130
Anzahl Schauspieler (S)	130	120	110	140	150	135	160	170
Erfolgreichster Film [Nr.] (E)	47	68	90	63	57	59	48	13

2.1 UNIVARIATE STATISTIK

Berechnen Sie **für das Filmbudget B (Zeile 1 der Tabelle)** die folgenden Größen.

(a) (2 Punkte) Modalwert

(b) (2 Punkte) Arithmetisches Mittel (Mittelwert)

(c) (2 Punkte) Median

(d) (2 Punkte) Wie würden sich Mittelwert (MW) und Median (Med) verändern, wenn zu den gegebenen Budgets noch ein Budget von 500 Millionen \$ hinzukäme? Kreuzen Sie in der untenstehenden Liste die richtige Lösung an und begründen Sie Ihre Meinung.

a) MW und Med bleiben ungefähr gleich
b) MW und Med vergrößern sich ungefähr gleich stark
c) MW vergrößert sich stärker als Med
d) Med vergrößert sich stärker als MW

(e) (2 Punkte) Welche ihrer berechneten Zahlen für Modalwert, Mittelwert, Median würden Sie verwenden, um das "typische" Budget eines Harry Potter Films anzugeben? Begründen Sie Ihre Meinung.

(f) (3 Punkte) Sie bitten Anna, Ben und Chris um Hilfe bei der Berechnung des 95%-Quantils. Anna berechnet 200.0, Ben berechnet 215.0 und Chris berechnet 250.0. Was ist die Bedeutung des 95%-Quantils? Und welche dieser Zahlen ist die richtige? Begründen Sie Ihre Meinung!

(g) (2 Punkte) empirische Standardabweichung (Std)

(h) (2 Punkte) Ben berechnet die Stichproben-Std (er verwendet das Python-Flag "ddof=0") und argumentiert, dass dies die "richtige" Std für das Budget der Harry Potter Filme sei. Was ist der Unterschied zur empirischen Std und welche ist hier die "richtige" Std? Begründen Sie Ihre Meinung.

2.2 Schliessende Statistik

(a) (2 Punkte) Verwenden Sie erwartungstreue, konsistente Schätzfunktionen, um basierend auf der obigen Stichprobe, Schätzwerte für das Budget eines Harry Potter Filmes zu berechnen für den wahren Mittelwert μ_B.

(b) (2 Punkte) Das 90%-Konfidenzintervall für den wahren Erwartungswert des Einspielergebnisses eines Harry Potter Films berechnet sich zu $[113.875; 174.875]$. Was sagt dieses Intervall aus?

(c) (3 Punkte) Ist Ihrer Meinung nach eine der erwähnten Schätzer sinnvoll, um das Budget der drei neu zu drehenden Harry Potter Filme abzuschätzen? Begründen Sie Ihre Meinung.

2.3 Multivariate Statistik

Film Nr.	1	2	3	4	5	6	7	8
Filmbudget [Millionen $] ($B$)	125	100	130	150	150	250	125	125
Filmlänge [min] (L)	152	161	142	157	138	153	146	130
Anzahl Schauspieler (S)	130	120	110	140	150	135	160	170
Erfolgreichster Film [Nr.] (E)	47	68	90	63	57	59	48	13

(a) (6 Punkte) Analysieren Sie nun den Zusammenhang zwischen dem Erscheinungsjahr, dem Budget, der Filmlänge, der Anzahl der Schauspieler und dem Erfolg des Films. Streichen Sie hierzu in der untenstehende Tabelle für jede Paarung den **falschen** empirischen Korrelationskoeffizienten (emp. KK) durch und geben Sie den Buchstaben des Scatterplots an, welcher zu dieser Kombination gehört.
Begründen Sie Ihre Entscheidung **kurz**!

Zusammenhang	emp. KK	Scatterplot	kurze Begründung
Filmbudget B und Erfolg E	0.486 0.072		
Filmlänge L und Erfolg E	0.486 -0.552		
Schauspieler S und Erfolg E	-0.854 0.072		

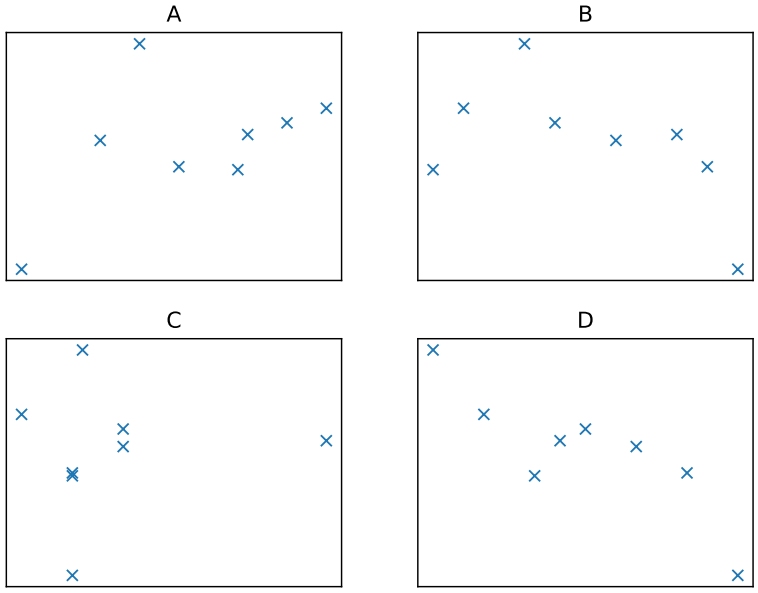


Abbildung 1: Welcher Scatterplot entspricht welchem Zusammenhang?

(b) (3 Punkte) Können Sie, basierend auf den Zahlen und Erkenntnissen, **zwei** Faktoren angeben, welche die Warner Bros. Studios wie verändern können, um möglich erfolgreiche Harry Potter Nachfolgefilme zu produzieren? Begründen Sie Ihre Meinung.

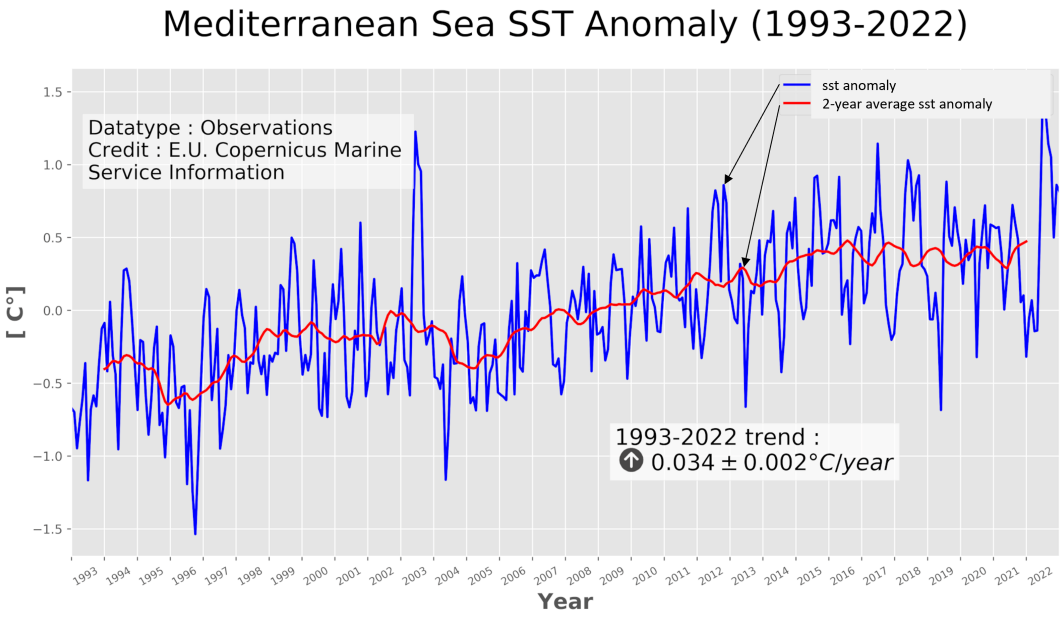


Abbildung 2: Time series of monthly mean (blue line) and 24-month averaged (red line) sea surface temperature anomalies in the Mediterranean Sea during the period 1993-2022. Anomalies are relative to the climatological period 1993-2014. Additionally, the sea surface temperature trend with its 95% confidence interval is shown in the box.

2.4 Zeitreihen

Betrachten Sie die obige Grafik und beantworten Sie folgende Fragen:

(a) (4 Punkte) Erklären Sie anhand der Abbildung und der Bildunterschrift in Ihren eigenen Worten, was die beiden verschiedenen Linien, sowie die Zahlen in der Box darstellen.

(b) (2 Punkte) Erklären Sie
- warum die Linie in der Mitte (“2-year average”) weniger zappelnd ist, als die andere Linie,
- wie sich die Werte dieser Linie berechnen.

(c) (2 Punkte) Was ist die Aussage dieses Diagramms Ihrer Meinung nach? Begründen Sie Ihre Meinung **kurz!**

AUFGABE 3, 23 PUNKTE
WAHRSCHEINLICHKEITSRECHNUNG

3.1 In der Prüfungsphase braut Professor Snape in großen Mengen Beruhigungstränke, welche alle Lehrkräfte sehr gerne trinken, bevor sie anfangen, Klausuren zu korrigieren.

Leider hat Professor Snape sich nicht gemerkt, welche Zaubertränke Zucker enthalten und welche nicht. Jeder Beruhigungs-Zaubertrank den Snape vorbereitet hat, enthält also mit einer Wahrscheinlichkeit von $\mathbf{p = 0.3}$ Zucker. Dies ist ein Problem, da viele der Lehrer:innen gerade eine Diät machen, und daher nur Beruhigungszaubertränke ohne Zucker möchten.

Da die Beruhigungszaubertränke für die Korrektur echt wichtig sind, entwickelt Professor McGonagall einen Schnelltest, mit dessen Hilfe erkannt werden kann, ob ein Zaubertrank Zucker enthält, oder nicht. Die **Sensitivität** des Tests (das Ergebnis eines Zaubertranks mit Zucker ist positiv) ist gleich **0.9**, dessen **Spezifität** (das Ergebnis eines Zaubertranks ohne Zucker ist negativ) ist gleich **0.8**.

Helfen Sie Professor McGonagall zu entscheiden, ob sie den Test so einsetzen kann oder überarbeiten muss! Erledigen Sie hierfür folgende Aufgaben:

(a) (4 Punkte) Modellieren Sie das beschriebene Szenario z.B. durch einen Wahrscheinlichkeitsbaum. Geben Sie alle aus dem Text ableitbaren Wahrscheinlichkeiten und Gegenwahrscheinlichkeiten der beschriebenen Ereignisse an. Verwenden Sie zur Modellierung die folgenden Ereignisse:

- Z : ein Zaubertrank enthält Zucker
- P : ein Zaubertrank hat ein positives Test-Ergebnis.

(b) (2 Punkte) Mit welcher Wahrscheinlichkeit fällt der Test negativ aus?

(c) (2 Punkte) Mit welcher Wahrscheinlichkeit ist der Test echt negativ?

(d) (3 Punkte) Mit welcher Wahrscheinlichkeit enthält ein negativ getesteter Zaubertrank keinen Zucker?

(e) (3 Punkte) Was ist Ihre Meinung: Kann Professor McGonagall den Schnelltest so einsetzen, oder sollte sie nochmal eine Woche Arbeit investieren, um entweder die Sensitivität oder die Spezifität zu verändern, wenn ja, wie? Begründen Sie Ihre Meinung Hilfe Ihrer obigen Überlegungen.

3.2 Professor Snape gibt für eine mündliche Prüfung im Fach Zaubertränke eine Liste von 10 Fragen aus. Jede:r Schüler:in bekommt für die Prüfung 2 zufällig aus den 10 Fragen ausgewählte Fragen vorgelegt und muss eine bearbeiten.

(a) (4 Punkte) Hermine bereitet sich auf 6 der 10 Fragen vor. Wie groß ist die Wahrscheinlichkeit dafür, dass Hermine mindestens eine vorbereitete Frage vorgelegt bekommt?

(b) (5 Punkte) Auch Harry bereitet sich auf 6 der 10 Fragen vor. Zu ihm ist Professor Snape allerdings besonders fies, daher bekommt Harry **drei** Fragen gestellt. Wie groß ist die Wahrscheinlichkeit dafür, dass Harry mindestens eine vorbereitete Frage vorgelegt bekommt?

AUFGABE 4, 36 PUNKTE
ZUFALLSVARIABLEN I

Francesca, George und Hamit studieren MSI und möchten anlässlich der Fußball-EM mit Wetten ein wenig Geld verdienen. Und natürlich möchten sie ihr Wissen über Zufallsvariablen anwenden, um ihre Wetten auch zu gewinnen.

Hinweis: Verwenden Sie bitte für die anschließenden Berechnungen **nicht** Ihr eventuell vorhandenes (Fußball)wissen, sondern lediglich die angegebene(n) Zufallsvariable(n)!

4.1 Nachdem das Spiel Dänemark gegen Deutschland wegen Unwetter abgebrochen ist, möchte George auf die, während eines Spiels fallende Regenmenge in mm, wetten. Hierfür verwendet sie die Zufallsvariable R, die wie folgt verteilt ist:

- R: Menge des während eines Fußballspiels fallenden Regens in mm ist normalverteilt mit Erwartungswert 20 und Standardabweichung 10.

(a) (2 Punkte) Mit welcher Wahrscheinlichkeit fällt während eines Fußballspiels weniger als 15 mm Regen?

(b) (2 Punkte) Welche Regenmenge wird nur in 5% aller Spiele überschritten?

(c) (3 Punkte) In welchem, symmetrisch um den Erwartungswert gelegenen Intervall, liegt die Menge des Niederschlags während eines Fußballspiels in 90% der Fälle?

(d) (3 Punkte) Was denken Sie: Ist die von George gewählte Zufallsvariable ein sinnvolles Modell, um die, während eines Fußballspiels fallende Regenmenge zu beschreiben? Begründen Sie Ihre Meinung.

4.2 Hamit konzentriert sich auf die Achtel-, Viertel-, Halb- und Finalspiele. Für diese muss es einen Gewinner geben, weswegen manchmal die Entscheidung im Elfmeterschießen (Schuss aufs Tor aus einer Entfernung von 11 Metern) fällt.

Hamit möchte die Leistung der französischen Mannschaft im Elfmeterschießen vorhersagen. Er nimmt an, dass bei $n = 10$ geschossenen Elfmetern, alle Elfmeter jeweils mit der gleichen Wahrscheinlichkeit von 80% ins Tor gehen und dass die Wahrscheinlichkeiten, dass ein Elfmeter trifft, jeweils voneinander unabhängig sind.

Hamit verwendet zur Beschreibung dieses Szenarios die folgenden Zufallsvariablen

- T: Anzahl der Elfmeter, welche von $n = 10$ geschossenen ins Tor treffen
- W Anzahl der Elfmeter, welche das französische Team schießen muss, bis ein Treffer dabei ist (Nehmen Sie hierfür vereinfachend an, dass unendlich geschossen wird).

(a) (2 Punkte) Geben Sie an, wie und mit welchen Parametern die Zufallsvariablen T und W verteilt sind.

(b) (3 Punkte) Mit welcher Wahrscheinlichkeit liegt die Anzahl von Treffern in in einer Serie von 10 geschossenen Elfmetern zwischen 5 und 7 einschließlich?

(c) (2 Punkte) Über welchem Wert liegt die Anzahl der Treffer in einer Serie von 10 geschossenen Elfmetern mit einer Wahrscheinlichkeit von 90%?

(d) (3 Punkte) Wie viele Elfmeter müssen mindestens geschossen werden, bis auf jeden Fall (mit einer Wahrscheinlichkeit von 100%) einer trifft?

(e) (3 Punkte) Was denken Sie: Ist die von Hamit gewählte Zufallsvariable ein sinnvolles Modell, um die während eines Elfmeterschießens erzielten Treffer vorherzusagen? Begründen Sie Ihre Meinung.

4.3 Francesca weiß, dass die Anzahl der Tore, die eine Mannschaft in einem Fußballspiel schießt, Poisson-verteilt ist. Sie möchte auf den Ausgang des Spiels Spanien gegen die Niederlande tippen, weswegen sie folgende Zufallsvariablen verwendet:

- N: die Anzahl der Tore, welche die Niederlande pro Spiel schießen ist Poisson-verteilt mit Rate $\lambda_N = 1$.
- S: die Anzahl der Tore, welche Spanien pro Spiel schießt ist Poisson-verteilt mit Rate $\lambda_S = 3$.
- Z: Zeit **in Minuten** die zwischen zwei Toren (egal welcher Mannschaft) liegt, ist exponentialverteilt mit Erwartungswert $\mathrm{E}(Z) = \frac{90}{4} = 22.5$.

(a) (3 Punkte) Begründen Sie, welche Annahmen man treffen muss, um die Zeit zwischen zwei Toren durch die, wie oben gegebene Zufallsvariable Z beschreiben zu können. Was denken Sie: Sind diese Annahmen gerechtfertigt? Ist dies ein gutes Modell? Begründen Sie Ihre Meinung.

(b) (2 Punkte) Mit welcher Wahrscheinlichkeit schießt Spanien in einem Spiel genau 2 Tore?

(c) (3 Punkte) Mit welcher Wahrscheinlichkeit schießen die Niederlande in einem Spiel mindestens 2 Tore?

(d) (2 Punkte) Mit welcher Wahrscheinlichkeit ist der Abstand zwischen zwei Toren (egal welcher Mannschaft) genau 3 Minuten?

(e) (3 Punkte) Welche Zeit zwischen zwei Toren (egal welcher Mannschaft) wird in 90% der Fälle nicht überschritten?

AUFGABE 5, 30 PUNKTE
ZUFALLSVARIABLEN II

Der Fußball-Weltverband (FIFA) möchte die Fußballspiele spannender machen, und beschließt, dass Spiele in Zukunft $90+x$ Minuten dauern, wobei x während des Spiels zufällig geniert wird. Daniel und Emily haben von der FIFA die Aufgabe bekommen, Timer zu entwickeln, welche Werte von -3 bis 3 annehmen. Daniel verwendet für einen zufällig für eine zufällig Zeit die **diskrete** Zufallsvariable D, Emily verwendet die **stetige** Zufallsvariable E, die wie folgt spezifiziert sind:

5.1

Verteilung von D (V_D):

d	-3	-2	-1	0	1	2	3
$P(D=d)$	$\frac{3}{12}$	$\frac{2}{12}$	$\frac{1}{12}$	$\frac{0}{12}$	$\frac{1}{12}$	$\frac{2}{12}$	$\frac{3}{12}$

Verteilungsdichtefunktion von E:

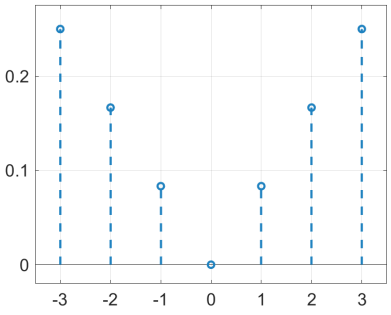
$$f_E(x) = \begin{cases} 0 & \text{für } x < -3 \\ \frac{1}{18}x^2 & \text{für } -3 \leq x \leq 3 \\ 0 & \text{für } x > 3 \end{cases}$$

(a) (6 Punkte) Punkte) Geben Sie für die Zufallsvariablen D und E deren Verteilungsfunktionen F_D ($2\frac{1}{2}$ Punkte) und F_E ($3\frac{1}{2}$ Punkte) an.

(b) (4 Punkte) Berechnen Sie für die Zufallsvariablen D und E jeweils die Wahrscheinlichkeit, dass eine zufällig erzeugte Zeit mindestens 2 ist.

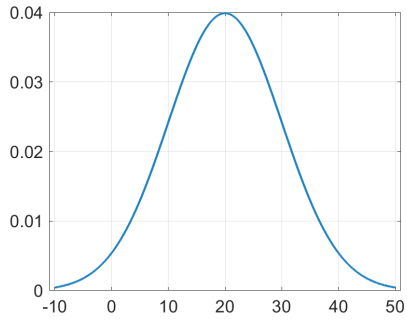
(c) (4 Punkte) Berechnen Sie den Erwartungswert der Zufallsvariablen D und E, bzw. schätzen Sie diese und begründen Sie Ihre Schätzung!

5.2 (9 Punkte) Kreuzen Sie für jedes der folgenden Diagramme an, ob es sich um die Verteilung der ZV D (V_D) oder der ZV T (V_D) (aus Aufgabe 4.2) handelt, um die Funktionen f_E, F_E, F_D, oder um die Dichte der ZV N (f_N) (aus Aufgabe 4.1) (je 1 Punkte). Begründen Sie Ihre Meinung kurz (je 0.5 Punkte)!



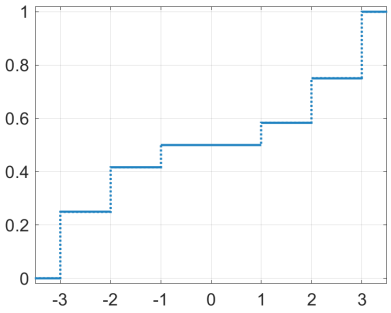
$V_D\square$ $V_T\square$ $f_E\square$ $f_N\square$ $F_D\square$ $F_E\square$

Begründung:



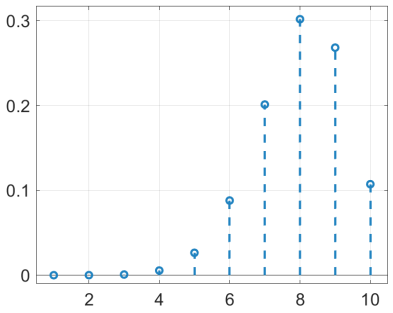
$V_D\square$ $V_T\square$ $f_E\square$ $f_N\square$ $F_D\square$ $F_E\square$

Begründung:



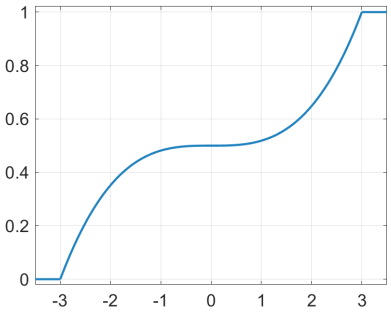
$V_D\square$ $V_T\square$ $f_E\square$ $f_N\square$ $F_D\square$ $F_E\square$

Begründung:



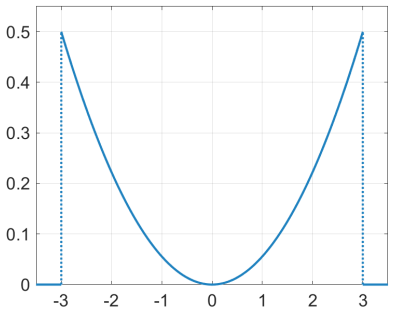
$V_D\square$ $V_T\square$ $f_E\square$ $f_N\square$ $F_D\square$ $F_E\square$

Begründung:



$V_D\square$ $V_T\square$ $f_E\square$ $f_N\square$ $F_D\square$ $F_E\square$

Begründung:



$V_D\square$ $V_T\square$ $f_E\square$ $f_N\square$ $F_D\square$ $F_E\square$

Begründung:

5.3 MEHRDIMENSIONALE ZV

Die stochastisch unabhängigen stetigen Zufallsvariablen X und Y besitzen die folgenden Dichtefunktionen:

$$\begin{aligned} f_1(x) &= \tfrac{1}{4}(x+1) \quad 0 \le x \le 2 \\ f_2(y) &= y + \tfrac{1}{2} \qquad 0 \le y \le 1 \end{aligned}$$

(im übrigen Bereich verschwinden beide Funktionen, sind also jeweils $= 0$).

Geben Sie für jede der folgenden Berechnungen an, ob sie korrekt ist oder nicht. Begründen Sie Ihre Meinung und korrigieren Sie ggf. Fehler.

(a) (2 Punkte) Die Dichtefunktion $f_{1,2}(x,y)$ der gemeinsamen Verteilung von X und Y ist gegeben wie folgt:

$$f_{1,2}(x,y) = f_1(x) + f_2(y) = \frac{1}{4}(x+1) + y + \frac{1}{2} = \frac{x}{4} + y + \frac{3}{4}.$$

(b) (3 Punkte) Die Verteilungsfunktion $F_{1,2}(x,y)$ der gemeinsamen Verteilung von X und Y ist gegeben durch

$$\begin{aligned} F_{1,2}(x,y) &= \int_{-\infty}^{y}\int_{-\infty}^{x} f_{1,2}(u,v)\,\mathrm{d}u\,\mathrm{d}v \\ &= \tfrac{1}{8}\int_{-\infty}^{y}\int_{-\infty}^{x} 2uv + u + 2v + 1\,\mathrm{d}u\,\mathrm{d}v = \tfrac{1}{8}\int_{-\infty}^{y}\left[vu^2 + \tfrac{1}{2}u^2 + 2vu + u\right]_0^x\,\mathrm{d}v \\ &= \tfrac{1}{8}\int_{-\infty}^{y} vx^2 + \tfrac{1}{2}x^2 + 2vx + x\,\mathrm{d}v = \tfrac{1}{8}\left[\tfrac{1}{2}v^2x^2 + \tfrac{1}{2}x^2v + v^2x + xv\right]_0^y \\ &= \tfrac{1}{8}(\tfrac{1}{2}y^2x^2 + \tfrac{1}{2}x^2y + y^2x + xy) = \tfrac{xy}{16}(xy + x + 2y + 2) \end{aligned}$$

(c) (2 Punkte) Die Kovarianz von X und Y, $\mathrm{Cov}(X,Y)$ ist gegeben durch

$$\mathrm{Cov}(X,Y) = \mathrm{E}(XY) - \mathrm{E}(X)\cdot\mathrm{E}(Y) = \mathrm{E}(X)\cdot\mathrm{E}(Y) - \mathrm{E}(X)\cdot\mathrm{E}(Y) = 0.$$