VLM - Visual Language Model
RL - Reinforced Learning (online vs offline)
Samples, Reasoning Steps
STF - Supervised Fine Tuning

Align with human values and expectations vs creativity, helpfulness, and reasoning.

VLM guard models = AI Firewall

The existing VLM guard models are trained to output only classification results. Although effective, they lack interpretability, as the models do not justify their decisions.

Goal: Reasoning Based VLM guard models

Challenges: Limited Data, Offline Training, Token Efficency

GuardReasoner-VL:
123K samples (Datensatz mit Prompt + erwünschte ausgabe) Prompt = Text/Image/Text+Image
631K reasoning steps (Erwünschte Zwischenschritte von Prompt zu Antwort)

Training Pipeline:
    Model Cold Start with Samples
    Data Concatenation (Kombination von Prompts)
    Online RL

Detail:
Reasoning Supervised Fine-Tuning (R-SFT)
Data Concatenation/Augmentation
Group relative policy optimization (GRPO) Mehrere Antworten relativ zueinander bewerten
    Omit KL divergence loss ("Strafe" für abweichende Verteilung der Antworten)
Dynamic clipping parameter: Gewichte werden im frühen Stadium stark aktualisiert, später schwächer

Reward Design:
Reward für Antwort Format(<think> Reasoning Steps <\think> <result> Ergebnis (harmfull/unharmfull)<\result>
Reward für mehr Reasoning Steps bei falscher Antwort mit cutoff

Ergebnisse:
GuardReasoner und andere Modelle auf den Datensatz loslassen, Richtige Klassifizierungen zählen (F1 Score)
GuardReasoner bei ~75%, andere Modelle bei 50-60%

Ablation Study (Auswertung nach bestimmter Stufe)
Insgesamt kleine Unterschiede, gerade Online RL im Bereich 77-79%
STF = Auf kombinierten Daten
R-STF = angeblich auch, aber wie ist das Möglich?
    R-STF auf jeweils Text/Image/Text+Image alleine liegen jeweils darunter.
Interessant: Modell tut sich schwer mit reinen Images
Unterschied zwischen 3B und 7B auch sehr gering (~0.5%)

GuardReasoner-VL-Eco 1-2% Verlust im F1 Score, dafür ~10% weniger tokens