

4 Multivariate Differentiation

4.2 zweiter Ordnung
4.3 diskrete Ableitungen


Mathe II

HTWG - Fakultät für Informatik

Prof. Dr. R. Axthelm


Multivariate Differentiation

Ableitungsterme zweiter Ordnung
von diskreten, multivariaten Funktionen



Ludwig-Otto Hesse
1811-1874


$$J\nabla f = \text{grad } \nabla f$$



Ludwig-Otto Hesse
1811-1874


$$J\nabla f = \text{grad } \nabla f = \text{grad} \begin{pmatrix} f_x \\ f_y \end{pmatrix}$$

$$J\nabla f = \text{grad } \nabla f = \text{grad} \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \text{grad } f_x \\ \text{grad } f_y \end{pmatrix}$$




Ludwig-Otto Hesse
1811-1874

$$J\nabla f = \text{grad } \nabla f = \text{grad} \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \text{grad}f_x \\ \text{grad}f_y \end{pmatrix} = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$$



Ludwig-Otto Hesse
1811-1874



Ludwig-Otto Hesse
1811-1874

$$J\nabla f = \text{grad } \nabla f = \text{grad} \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \text{grad} f_x \\ \text{grad} f_y \end{pmatrix} = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$$

Definition: Hesse-Matrix

Sei $f \in C^2(D \subseteq \mathbb{R}^n)$, also auf D zwei mal partiell differenzierbar. Dann heißt die Matrix

$$Hf = \begin{pmatrix} f_{x_1 x_1} & \cdots & f_{x_1 x_n} \\ \vdots & & \vdots \\ f_{x_n x_1} & \cdots & f_{x_n x_n} \end{pmatrix}$$

Hesse-Matrix der Funktion f .

Dabei meint

$$f_{x_i x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} = \frac{\partial}{\partial x_j} \frac{\partial}{\partial x_i} f$$

erste partielle Ableitung in Richtung x_i und zweite partielle Ableitung in Richtung x_j .

Beispiel: Hesse-Matrix

Beispiel:

Für $f(x) = 2x_1^2 x_2 + x_2^3$

$$f_{x_1} = 4x_1 x_2, \quad f_{x_2} = 2x_1^2 + 3x_2^2,$$

$$f_{x_1 x_1} = 4x_2, \quad f_{x_1 x_2} = 4x_1,$$

$$f_{x_2 x_1} = 4x_1, \quad f_{x_2 x_2} = 6x_2.$$

Die Hesse-Matrix lautet dann

$$Hf = \begin{pmatrix} 4x_2 & 4x_1 \\ 4x_1 & 6x_2 \end{pmatrix}.$$

Beispiel: Hesse-Matrix

Beispiel:

Für $f(x) = 2x_1^2 x_2 + x_2^3$

$$\begin{array}{ll} f_{x_1} = 4x_1 x_2, & f_{x_2} = 2x_1^2 + 3x_2^2, \\ f_{x_1 x_1} = 4x_2, & f_{x_1 x_2} = 4x_1, \\ f_{x_2 x_1} = 4x_1, & f_{x_2 x_2} = 6x_2. \end{array}$$

Die Hesse-Matrix lautet dann

$$Hf = \begin{pmatrix} 4x_2 & 4x_1 \\ 4x_1 & 6x_2 \end{pmatrix}.$$

Definition & Satz: Extrema

Stellen $x \in \mathbb{D}_u$ heißen kritische Punkte von u , wenn

$$\|\nabla u(x)\| = 0$$

gilt.

u hat bei x ein lokales Minimum, wenn $Hu(x)$ positiv definit ist, d.h., dass die Matrix nur positive Eigenwerte besitzt.

u hat bei x ein lokales Maximum, wenn $Hu(x)$ negativ definit ist, d.h., dass die Matrix nur negative Eigenwerte besitzt.


Maximum oder Minimum

$$u(x) = x_1^2 + x_2^2$$

$$P_K = (0, 0)$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

$\lambda = 2 \Rightarrow$ positiv definit




Maximum oder Minimum

$$u(x) = x_1^2 + x_2^2$$

$$P_K = (0, 0)$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$


$\lambda = 2 \Rightarrow$ positiv definit



$$u(x) = -x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}$$

$\lambda = -2 \Rightarrow$ negativ definit




Maximum oder Minimum

$$u(x) = x_1^2 + x_2^2$$

$$P_K = (0, 0)$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$


$\lambda = 2 \Rightarrow$ positiv definit



$$u(x) = -x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}$$


$\lambda = -2 \Rightarrow$ negativ definit



$$u(x) = x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$$

$\lambda \in \{-2, 2\} \Rightarrow$ indefinit



4. Multivariate Differentiation

Ableitungsterme zweiter Ordnung


Maximum oder Minimum

$$u(x) = x_1^2 + x_2^2$$

$$P_K = (0, 0)$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$


$\lambda = 2 \Rightarrow$ positiv definit



$$u(x) = -x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}$$


$\lambda = -2 \Rightarrow$ negativ definit



$$u(x) = x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$$

$\lambda \in \{-2, 2\} \Rightarrow$ indefinit




$$u(x) = 2x_1^2(1-x_2) + (x_2+1)^3$$


$$P_k = (-1, 0)$$

$$Hu(P_k) = \begin{pmatrix} 8 & 0 \\ 0 & 0 \end{pmatrix}$$



$\lambda \in \{8, 0\} \Rightarrow$ pos. semi definit




Baywatch: Optimierungsproblem




Memo: Schnellster Weg zur Ertrinkenden:



Baywatch: Optimierungsproblem



allgemein:

benötigte Zeit $T(y)$ und partielle Ableitungen $T_{,y_j}$



$$T(y) = \sum_{i=0}^{n-1} \frac{1}{v_i} \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2}$$

$$\begin{aligned} (\tau_{,y_j})_j(y) &= \left(\frac{y_j - y_{j-1}}{v_{j-1} \sqrt{(x_j - x_{j-1})^2 + (y_j - y_{j-1})^2}} \right. \\ &\quad \left. - \frac{y_{j+1} - y_j}{v_j \sqrt{(x_{j+1} - x_j)^2 + (y_{j+1} - y_j)^2}} \right)_j \end{aligned}$$

4. Multivariate Differentiation

Ableitungsterme zweiter Ordnung

Baywatch: Optimierungsproblem



Satz

Sei $D \subseteq \mathbb{R}^n$ und $f \in C^2(D)$, dann gilt

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} \quad \forall 1 \leq i, j \leq n.$$

(ohne Beweis)

Satz

Sei $D \subseteq \mathbb{R}^n$ und $f \in C^2(D)$, dann gilt

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} \quad \forall 1 \leq i, j \leq n.$$

(ohne Beweis)

Definition: Laplace-Operator

Zu einer skalaren Funktion $u : \mathbb{R}^n \rightarrow \mathbb{R}$ heißt die Abbildung

$$\Delta u = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \sum_{i=1}^n u_{x_i x_i}$$

Laplace von u. Der Operator Δ heißt *Laplace Operator*.

Memo:

$$\Delta u = u_{x_1} x_1 + \dots + u_{x_n} x_n = \sum_{i=1}^n u_{x_i} x_i$$

Memo:

$$\Delta u = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \sum_{i=1}^n u_{x_i x_i}$$

Beispiel:

$$\Delta x_1^2 + \cos x_2 = (x_1^2 + \cos x_2)_{x_1 x_1} + (x_1^2 + \cos x_2)_{x_2 x_2} = (2 x_1)_{x_1} - (\sin x_2)_{x_2} = 2 - \cos x_2$$

Memo:

$$\Delta u = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \sum_{i=1}^n u_{x_i x_i}$$

Beispiel:

$$\Delta(x_1^2 + \cos x_2) = (x_1^2 + \cos x_2)_{x_1 x_1} + (x_1^2 + \cos x_2)_{x_2 x_2} = (2x_1)_{x_1} - (\sin x_2)_{x_2} = 2 - \cos x_2$$



Der Laplace von u ist gleich der Spur der Hesse-Matrix.

Memo:

$$\Delta u = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \sum_{i=1}^n u_{x_i x_i}$$

Beispiel:

$$\Delta(x_1^2 + \cos x_2) = (x_1^2 + \cos x_2)_{x_1 x_1} + (x_1^2 + \cos x_2)_{x_2 x_2} = (2x_1)_{x_1} - (\sin x_2)_{x_2} = 2 - \cos x_2$$



Der Laplace von u ist gleich der Spur der Hesse-Matrix.

Beispiel:

$$\Delta u = \text{Spur } Hu = \text{Spur} \begin{pmatrix} 2 & 0 \\ 0 & -\cos x_2 \end{pmatrix} = 2 - \cos x_2$$

Die Hesse-Matrix von u ist auch die Jacobi-Matrix von ∇u . Daher ist der Laplace-Operator von u auch die Divergenz des Gradienten von u :

$$\Delta u = \nabla \cdot \nabla u$$

Die Hesse-Matrix von u ist auch die Jacobi-Matrix von ∇u . Daher ist der Laplace-Operator von u auch die Divergenz des Gradienten von u :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u$$

Die Hesse-Matrix von u ist auch die Jacobi-Matrix von ∇u . Daher ist der Laplace-Operator von u auch die Divergenz des Gradienten von u :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u = \nabla \cdot \begin{pmatrix} u_{x_1} \\ \vdots \\ u_{x_n} \end{pmatrix}$$

Die Hesse-Matrix von u ist auch die Jacobi-Matrix von ∇u . Daher ist der Laplace-Operator von u auch die Divergenz des Gradienten von u :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u = \nabla \cdot \begin{pmatrix} u_{x_1} \\ \vdots \\ u_{x_n} \end{pmatrix} = \frac{\partial}{\partial x_1} u_{x_1} + \cdots + \frac{\partial}{\partial x_n} u_{x_n}$$

Die Hesse-Matrix von u ist auch die Jacobi-Matrix von ∇u . Daher ist der Laplace-Operator von u auch die Divergenz des Gradienten von u :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u = \nabla \cdot \begin{pmatrix} u_{x_1} \\ \vdots \\ u_{x_n} \end{pmatrix} = \frac{\partial}{\partial x_1} u_{x_1} + \cdots + \frac{\partial}{\partial x_n} u_{x_n} = u_{x_1 x_1} + \cdots + u_{x_n x_n}$$

Die Hesse-Matrix von u ist auch die Jacobi-Matrix von ∇u . Daher ist der Laplace-Operator von u auch die Divergenz des Gradienten von u :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u = \nabla \cdot \begin{pmatrix} u_{x_1} \\ \vdots \\ u_{x_n} \end{pmatrix} = \frac{\partial}{\partial x_1} u_{x_1} + \cdots + \frac{\partial}{\partial x_n} u_{x_n} = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \Delta u$$

Übersicht

Abbildung	1. Ableitung	2. Ableitung
$f : \mathbb{R}^n \rightarrow \mathbb{R}$ $\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \mapsto f(x_1, \dots, x_n)$	Gradient $\nabla f = \begin{pmatrix} f_{x_1} \\ \vdots \\ f_{x_n} \end{pmatrix}$	Hessematrix $Hf = \text{grad } \nabla f = \begin{pmatrix} f_{x_1 x_1} & \cdots & f_{x_1 x_n} \\ \vdots & \ddots & \vdots \\ f_{x_n x_1} & \cdots & f_{x_n x_n} \end{pmatrix}$
		Laplace $\Delta f = \sum_{i=1}^n f_{x_i x_i}$

Bemerkung: Der Gradient zeigt in Richtung des steilsten Anstiegs

Der Laplace ist die Divergenz des Gradienten: $\Delta f = \nabla \cdot \nabla f$

und die Spur der Hessematrix: $\Delta f = \text{Spur } Hf$

Richtungsableitungen		
$v, w \in \mathbb{R}^n, \ w\ = \ v\ = 1$	$f_v = \nabla f \cdot v$	$f_{vw} = v^T Hf w$
$u, g : \mathbb{R}^n \rightarrow \mathbb{R}^n$ $\ u(x)\ = \ g(x)\ = 1 \quad \forall x \in \mathbb{R}^n$	$f_{u(x)g(x)} = \nabla f(x) \cdot u(x)$	$\begin{aligned} f_{u(x)g(x)} &= \\ u(x)^T Hf(x) g(x) &+ \nabla f(x)^T Du g(x) \end{aligned}$
$g : \mathbb{R} \rightarrow \mathbb{R}^m$ $t \mapsto \begin{pmatrix} g_1(t) \\ \vdots \\ g_m(t) \end{pmatrix}$	$g'(t) = \begin{pmatrix} g'_1(t) \\ \vdots \\ g'_m(t) \end{pmatrix}$	$g''(t) = \begin{pmatrix} g''_1(t) \\ \vdots \\ g''_m(t) \end{pmatrix}$

Bemerkung: Alle Ableitungen werden kptw durchgeführt

Jacobi-Matrix $Df =$		
$\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \mapsto \begin{pmatrix} f_1(x_1, \dots, x_n) \\ \vdots \\ f_m(x_1, \dots, x_n) \end{pmatrix}$		$\begin{pmatrix} f_{1,x_1} & \cdots & f_{1,x_n} \\ \vdots & \ddots & \vdots \\ f_{m,x_1} & \cdots & f_{m,x_n} \end{pmatrix}$

Bemerkung: Die Jacobi-Matrix des Gradienten ist die Hessematrix: $D\nabla f = Hf$

Divergenz		
$f : \mathbb{R}^n \rightarrow \mathbb{R}^m$	$\nabla \cdot f = \sum_{i=1}^n f_{i,x_i}$	

Bemerkung: Die Divergenz ist die Spur der Jacobi-Matrix

Kettenregel:	$f : \mathbb{R}^n \rightarrow \mathbb{R}, g : \mathbb{R} \rightarrow \mathbb{R}^n$
	$\frac{d}{dt}(f \circ g)(t) = \sum_{i=1}^n f_{g_i}(g'_i(t)) = \nabla f(g) \cdot g'(t)$

Lernziele



- Sie können zweite partielle Ableitungen einer multivariaten Funktion berechnen.
- Sie können die Hesse-Matrix und den Lapalce einer multivariaten Funktion berechnen.
- Sie können kritische Punkte von multivariaten Funktionen berechnen und Sie wissen wie Sie auch Maxima und Minima prüfen.
- Sie können Querverbindungen zwischen Hesse-Matrix, Divergenz, Gradient, etc. aufzeigen und erklären.


4. Multivariate Differentiation

von diskreten, multivariaten Funktionen

digitale Bilder als diskrete Funktionen



Pixelmatrix eines Bildes ...



... als Graph einer diskreten Funktion

digitale Bilder als diskrete Funktionen

Definition: digitale Bilder als diskrete Funktionen

Auf den Indexmengen $I_N = [1, N] \cap \mathbb{N}$ und $I_M = [1, M] \cap \mathbb{N}$ werden folgende Abbildungen definiert:
8-bit, RGB:

$$\begin{aligned} P : I_M \times I_N &\subset \mathbb{N}^2 \rightarrow [0, 255]^3 \\ (i, j) &\mapsto (P_{ij}^R, P_{ij}^G, P_{ij}^B) \end{aligned}$$

skaliert, grauwertig:

$$\begin{aligned} P : I_M \times I_N &\subset \mathbb{N}^2 \rightarrow [0, 1] \\ (i, j) &\mapsto P_{ij} \end{aligned}$$

Ableitung erster Ordnung

Definition: Differenzenquotient für partielle Ableitungen

in x - und y -Richtung:

$$u_x^+ \approx \frac{u(x+h, y) - u(x, y)}{h} \quad \text{Vorwärtsdifferenzenquotient}$$

$$u_x^- \approx \frac{u(x, y) - u(x-h, y)}{h} \quad \text{Rückwärtsdifferenzenquotient}$$

$$u_x^\pm \approx \frac{1}{2} (u_x^+ + u_x^-) \quad \text{gemittelter Differenzenquotient}$$


$$u_y^+ \approx \frac{u(x, y+h) - u(x, y)}{h} \quad \text{Vorwärtsdifferenzenquotient}$$

$$u_y^- \approx \frac{u(x, y) - u(x, y-h)}{h} \quad \text{Rückwärtsdifferenzenquotient}$$

$$u_y^\pm \approx \frac{1}{2} (u_y^+ + u_y^-) \quad \text{gemittelter Differenzenquotient}$$

Ableitung erster Ordnung

$$\mathcal{P}_{ij} = \begin{pmatrix} P_{i-1,j-1} & P_{i-1,j} & P_{i-1,j+1} \\ P_{i,j-1} & P_{i,j} & P_{i,j+1} \\ P_{i+1,j-1} & P_{i+1,j} & P_{i+1,j+1} \end{pmatrix}$$



Ableitung erster Ordnung

$$\mathcal{P}_{ij} = \begin{pmatrix} P_{i-1,j-1} & P_{i-1,j} & P_{i-1,j+1} \\ P_{i,j-1} & P_{i,j} & P_{i,j+1} \\ P_{i+1,j-1} & P_{i+1,j} & P_{i+1,j+1} \end{pmatrix}$$

$$= \begin{pmatrix} u(x-1, y-1) & u(x, y-1) & u(x+1, y-1) \\ u(x-1, y) & u(x, y) & u(x+1, y) \\ u(x-1, y+1) & u(x, y+1) & u(x+1, y+1) \end{pmatrix}$$

$$h = 1$$

A =
 P₃₃

0	0	0	128	100	20	20
0	128	100	20	20	100	100
128	200	100	200	200	100	100
0	128	254	254	254	200	200
128	254	254	254	254	200	200
0	10	254	200	100	100	100
10	254	254	254	254	200	200
10	254	254	254	254	200	200

Definition: partielle Ableitungen eines digitalen Bildes

$$P_{ij,x}^+ \approx P_{i,j+1} - P_{i,j}$$

Vorwärtsdifferenzenquotient

$$P_{ij,x}^- \approx P_{i,j} - P_{i,j-1}$$

Rückwärtsdifferenzenquotient

$$P_x^\pm \approx \frac{1}{2} (P_{i,j+1} - P_{i,j-1})$$

gemittelter Differenzenquotient

$$P_{ij,y}^+ \approx P_{i+1,j} - P_{i,j}$$

Vorwärtsdifferenzenquotient

$$P_{ij,y}^- \approx P_{i,j} - P_{i-1,j}$$

Rückwärtsdifferenzenquotient

$$P_y^\pm \approx \frac{1}{2} (P_{i+1,j} - P_{i-1,j})$$

gemittelter Differenzenquotient

$$\Rightarrow \nabla_h P_{ij} = \frac{1}{2} \begin{pmatrix} P_{i,j+1} - P_{i,j-1} \\ P_{i+1,j} - P_{i-1,j} \end{pmatrix} \quad \text{Gradient über gemittelte Diff.-quot.}$$

Beispiel: Gradient und Richtungsableitung



Für das Patch

$$\mathcal{P}_{ij} = \left(\begin{array}{c|c|c} 1 & 6 & 0 \\ \hline 1 & 3 & 2 \\ \hline 0 & 1 & 9 \end{array} \right)$$

Beispiel: Gradient und Richtungsableitung



Für das Patch

$$\mathcal{P}_{ij} = \left(\begin{array}{c|cc|c} 1 & 6 & 0 \\ \hline 1 & 3 & 2 \\ \hline 0 & 1 & 9 \end{array} \right)$$

erhalten wir den diskreten Gradienten

$$\begin{aligned}\nabla_h P_{ij} &= \frac{1}{2} \left(\begin{matrix} P_{i,j+1} - P_{i,j-1} \\ P_{i+1,j} - P_{i-1,j} \end{matrix} \right) \\ &= \frac{1}{2} \begin{pmatrix} 2 - 1 \\ 1 - 6 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 \\ -5 \end{pmatrix}\end{aligned}$$

Beispiel: Gradient und Richtungsableitung



Für das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 6 & 0 \\ 1 & 3 & 2 \\ 0 & 1 & 9 \end{pmatrix}$$

erhalten wir den diskreten Gradienten

$$\begin{aligned}\nabla_h P_{ij} &= \frac{1}{2} \left(\begin{matrix} P_{i,j+1} - P_{i,j-1} \\ P_{i+1,j} - P_{i-1,j} \end{matrix} \right) \\ &= \frac{1}{2} \begin{pmatrix} 2 - 1 \\ 1 - 6 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 \\ -5 \end{pmatrix}\end{aligned}$$



Beispiel: Gradient und Richtungsableitung



Für das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 6 & 0 \\ 1 & 3 & 2 \\ 0 & 1 & 9 \end{pmatrix}$$

erhalten wir den diskreten Gradienten

$$\begin{aligned}\nabla_h P_{ij} &= \frac{1}{2} \left(\begin{matrix} P_{i,j+1} - P_{i,j-1} \\ P_{i+1,j} - P_{i-1,j} \end{matrix} \right) \\ &= \frac{1}{2} \left(\begin{matrix} 2 - 1 \\ 1 - 6 \end{matrix} \right) = \frac{1}{2} \left(\begin{matrix} 1 \\ -5 \end{matrix} \right)\end{aligned}$$

Kennlinie

$$C(\|\nabla P\|) = \frac{\beta}{\sqrt{\beta^2 + \|\nabla P\|^2}}$$

<https://www.geogebra.org/m/dsvjj4b4>



4. Multivariate Differentiation

von diskreten, multivariaten Funktionen


Beispiel: Gradient und Richtungsableitung



$$\square \quad \beta = 0.1 \quad \leftrightarrow \quad \square$$

$$\square \quad \beta = 0.3 \quad \leftrightarrow \quad \square$$

$$C(\|\nabla P\|) = \frac{\beta}{\sqrt{\beta^2 + \|\nabla P\|^2}}$$



4. Multivariate Differentiation

von diskreten, multivariaten Funktionen


Beispiel: Gradient und Richtungsableitung



$$\square \leftrightarrow \beta = 0.1 \quad \times \times$$

$$\times \times \leftrightarrow \beta = 0.3 \quad \square$$

$$C(\|\nabla P\|) = \frac{\beta}{\sqrt{\beta^2 + \|\nabla P\|^2}}$$



Beispiel: Gradient und Richtungsableitung



Patch:

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 6 & 0 \\ 1 & 3 & 2 \\ 0 & 1 & 9 \end{pmatrix}$$

Gradient:

$$\nabla_h P_{ij} = \frac{1}{2} \begin{pmatrix} 1 \\ -5 \end{pmatrix}, \quad \|\nabla_h P_{ij}\| \approx 2.55$$

Richtungsableitung:

$$P_{ij,v} \text{ in Richtung } v = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\begin{aligned} P_{ij,v} &= \nabla_h P_{ij} \cdot v \frac{1}{\|v\|} \\ &= \frac{1}{2} \begin{pmatrix} 1 \\ -5 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} \frac{1}{\sqrt{2}} \\ &= -\sqrt{2} \approx -1.41 \end{aligned}$$



partielle Ableitungen zweiter Ordnung

Definition: Laplace-Operator für diskrete Funktionen

$$\begin{aligned} u_{h,xx} &= \frac{u(x+h, y) - 2u(x, y) + u(x-h, y)}{h^2} \\ u_{h,yy} &= \frac{u(x, y+h) - 2u(x, y) + u(x, y-h)}{h^2} \\ \Rightarrow \Delta_h u &= \frac{u(x+h, y) - u(x-h, y) + u(x, y+h) - u(x, y-h) - 4u(x, y)}{h^2} \end{aligned}$$

partielle Ableitungen zweiter Ordnung

Definition: Laplace-Operator für diskrete Funktionen

$$u_{h,xx} = \frac{u(x+h, y) - 2u(x, y) + u(x-h, y)}{h^2}$$
$$u_{h,yy} = \frac{u(x, y+h) - 2u(x, y) + u(x, y-h)}{h^2}$$
$$\Rightarrow \Delta_h u = \frac{u(x+h, y) - u(x-h, y) + u(x, y+h) - u(x, y-h) - 4u(x, y)}{h^2}$$

Definition: Laplace-Operator für digitale Bilder

$$P_{ij,xx} = P_{i,j+1} - 2P_{ij} + P_{i,y-1}$$
$$P_{ij,yy} = P_{i+1,j} - 2P_{ij} + P_{i-1,y}$$
$$\Rightarrow \Delta_h P_{ij} = P_{i+1,j} + P_{i-1,y} + P_{i,j+1} + P_{i,y-1} - 4P_{ij}$$

0	1	0
1	-4	1
0	1	0

Beispiel

Für das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} P_{i-1,j-1} & P_{i-1,j} & P_{i-1,j+1} \\ \hline P_{i,j-1} & P_{i,j} & P_{i,j+1} \\ \hline P_{i+1,j-1} & P_{i+1,j} & P_{i+1,j+1} \end{pmatrix} = \begin{pmatrix} 1 & 2 & 3 \\ \hline 4 & 6 & 2 \\ \hline 2 & 5 & 9 \end{pmatrix}$$

erhalten wir die diskreten zweiten Ableitungen

$$P_{ij,xx} = 2 - 2 \cdot 6 + 4 = -6$$

$$P_{ij,yy} = 5 - 2 \cdot 6 + 2 = -5$$

und damit den Laplace

$$\Delta_h P_{ij} = -6 - 5 = -11$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

multiplizieren wir mit dem Filter \mathcal{F}_Δ

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}$$

multiplizieren wir mit dem Filter \mathcal{F}_Δ

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}$$

und summieren auf:

multiplizieren wir mit dem Filter \mathcal{F}_Δ

$$\Delta_h \mathcal{P}_{ij} = \sum_{l,k} (\mathcal{P}_{ij} : \mathcal{F}_\Delta)_{lk}$$

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

multiplizieren wir mit dem Filter \mathcal{F}_Δ

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}$$

und summieren auf:

$$\Delta_h \mathcal{P}_{ij} = \sum_{l,k} (\mathcal{P}_{ij} : \mathcal{F}_\Delta)_{lk}$$

$$= \sum_{l,k} \left(\begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix} \right)_{lk}$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

multiplizieren wir mit dem Filter \mathcal{F}_Δ

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}$$

und summieren auf:

$$\Delta_h \mathcal{P}_{ij} = \sum_{l,k} (\mathcal{P}_{ij} : \mathcal{F}_\Delta)_{lk}$$

$$= \sum_{l,k} \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}_{lk}$$

$$= 2 + 4 - 24 + 2 + 5 = -11$$

Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in x -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_x = \mathcal{P}_{ij} : \left(\begin{array}{c|c|c} \square & \square & \square \\ \hline \square & \square & \square \\ \hline \square & \square & \square \end{array} \right) ?$$

Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in x -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_{kj} = \mathcal{P}_{ij} : \left(\begin{array}{c|c|c} 0 & 0 & 0 \\ -0.5 & 0 & 0.5 \\ 0 & 0 & 0 \end{array} \right)$$

Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in x -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_{ij} = \mathcal{P}_{ij} : \left(\begin{array}{c|c|c} 0 & 0 & 0 \\ -0.5 & 0 & 0.5 \\ 0 & 0 & 0 \end{array} \right)$$

Wie lautet der Filter zur ersten, gemittelten Ableitung in y -Richtung:

$$P_{ij,y} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_y = \sum_{l,k} \mathcal{P}_{lj} : \left(\begin{array}{c|c|c} \square & \square & \square \\ \square & \square & \square \\ \square & \square & \square \end{array} \right) ?$$

Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in x -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_{kj} = \mathcal{P}_{ij} : \begin{pmatrix} 0 & 0 & 0 \\ -0.5 & 0 & 0.5 \\ 0 & 0 & 0 \end{pmatrix}$$

Wie lautet der Filter zur ersten, gemittelten Ableitung in y -Richtung:

$$P_{ij,y} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_{kj} = \sum_{l,k} \mathcal{P}_{lj} : \begin{pmatrix} 0 & -0.5 & 0 \\ 0 & 0 & 0 \\ 0 & 0.5 & 0 \end{pmatrix}$$

Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in x -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{ij} : \mathcal{F}_{ij} = \mathcal{P}_{ij} : \begin{pmatrix} 0 & 0 & 0 \\ -0.5 & 0 & 0.5 \\ 0 & 0 & 0 \end{pmatrix}$$

Wie lautet der Filter zur ersten, gemittelten Ableitung in y -Richtung:

$$P_{ij,y} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{ij} : \mathcal{F}_{ij} = \sum_{l,k} \mathcal{P}_{ij} : \begin{pmatrix} 0 & -0.5 & 0 \\ 0 & 0 & 0 \\ 0 & 0.5 & 0 \end{pmatrix}$$

Wie lautet der Filter zur ersten Ableitung (Vorwärtsdiff-quot) in x -Richtung:

$$P_{ij,x}^+ = \sum_{l,k} \mathcal{P}_{ij} : \mathcal{F}_y = \sum_{l,k} \mathcal{P}_{ij} : \begin{pmatrix} \square & \square & \square \\ \square & \square & \square \\ \square & \square & \square \end{pmatrix} ?$$

Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in x -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_{ij} = \mathcal{P}_{ij} : \begin{pmatrix} 0 & 0 & 0 \\ -0.5 & 0 & 0.5 \\ 0 & 0 & 0 \end{pmatrix}$$

Wie lautet der Filter zur ersten, gemittelten Ableitung in y -Richtung:

$$P_{ij,y} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_{ij} = \sum_{l,k} \mathcal{P}_{lj} : \begin{pmatrix} 0 & -0.5 & 0 \\ 0 & 0 & 0 \\ 0 & 0.5 & 0 \end{pmatrix}$$

Wie lautet der Filter zur ersten Ableitung (Vorwärtsdiff-quot) in x -Richtung:

$$P_{ij,x}^+ = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_{ij} = \sum_{l,k} \mathcal{P}_{lj} : \begin{pmatrix} 0 & 0 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & 0 \end{pmatrix}$$

Ausblick

Diffusionsgleichung (isotrop):

$$P_t - \Delta P = 0 \quad \Rightarrow \quad P^{neu} = P^{alt} + \delta \Delta P^{alt}$$

```
for l=1:LOOPmax
    P = P + delta*P:FΔ
end
```



Ausblick

Diffusionsgleichung (isotrop):

$$P_t - \Delta P = 0 \quad \Rightarrow \quad P^{neu} = P^{alt} + \delta \Delta P^{alt}$$

```
for l=1:LOOPmax
    P = P + delta*P:FΔ
end
```



Ausblick

Diffusionsgleichung (anisotrop):

$$P_t - P_{vv} = 0 \quad \Rightarrow \quad P^{neu} = P^{alt} + \delta P_{vv}^{alt}$$

$$P_{vv} = \frac{v_1^2}{\|v\|^2} P_{xx} + \frac{2 v_1 v_2}{\|v\|^2} P_{xy} + \frac{v_2^2}{\|v\|^2} P_{yy}$$

$$P_{xx} = \mathcal{P} : \mathcal{F}_{xx}, \dots$$

```
for l=1:LOOPmax
    P = P + delta*P_{vv}
end
```

$$v = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \frac{1}{\sqrt{2}}$$



Ausblick

Diffusionsgleichung (anisotrop):

$$P_t - P_{vv} = 0 \quad \Rightarrow \quad P^{neu} = P^{alt} + \delta P_{vv}^{alt}$$

$$P_{vv} = \frac{v_1^2}{\|v\|^2} P_{xx} + \frac{2 v_1 v_2}{\|v\|^2} P_{xy} + \frac{v_2^2}{\|v\|^2} P_{yy}$$

$$P_{xx} = \mathcal{P} : \mathcal{F}_{xx}, \dots$$

```
for l=1:LOOPmax
    P = P + delta*P_{vv}
end
```

$$v = \begin{pmatrix} 1 \\ -1 \end{pmatrix} \frac{1}{\sqrt{2}}$$



Ausblick

Diffusionsgleichung (anisotrop/bildabhängig):

$$P^{neu} = P^{alt} + \delta P_{\nabla P \nabla P}^{alt}$$

$P_{\nabla P \nabla P}$ lässt sich nicht mehr als Linearkombination von Filtern reiner partieller Ableitungen darstellen.

```
for l=1:LOOPmax
    P = P + delta*P_{\nabla P \nabla P}
end
```



Ausblick

Diffusionsgleichung (anisotrop/bildabhängig):


$$P^{neu} = P^{alt} + \delta P_{\nabla P^\perp \nabla P^\perp}^{alt}$$

$P_{\nabla P^\perp \nabla P^\perp}$ lässt sich nicht mehr als Linearkombination von Filtern reiner partieller Ableitungen darstellen.

```
for l=1:LOOPmax
    P = P + delta*P_{\nabla P^\perp \nabla P^\perp}
end
```



Ausblick



BiLeSA-App auf Google Play

Lernziele



- Sie können den Gradienten und eine beliebige Richtungsableitung einer diskreten, multivariaten Funktion berechnen.
- Sie können die Hessematrix und den Laplace-Operator einer diskreten, multivariaten Funktion berechnen.
- Sie können die Ableitungsterme in Filterschreibweise darstellen.
- Sie sind in der Lage einen Filter für die dritten Ableitungen aufzustellen. Es ist Ihnen klar, dass man sich nicht an das 3x3-Format halten muss.
- Die Grundidee wie man Optimierungsprobleme mit mehreren Freiheitsgraden (Unbekannte) löst ist Ihnen klar. Dabei ist selbstverständlich die Nullstellensuche ein separates Problem (Numerik).