Übungsblatt 3

Reguläre Sprachen und endliche Automaten

{Theoretische Informatik}@AIN3
Prof. Dr. Barbara Staehle
Wintersemester 2021/2022
HTWG Konstanz

Aufgabe 3.1 Reguläre Ausdrücke, Grammatiken und endliche Automaten

In dieser Aufgabe geht es um reguläre Ausdrücke, Grammatiken und endliche Automaten r_x, G_x, A_x welche jeweils die formale Sprache L_x erzeugen bzw. akzeptieren, wobei $x \in \{1, 2, \ldots, 12\}$.

Teilaufgabe 3.1.1 3 Punkte

Geben Sie alle Worte an, welche durch folgende reguläre Ausdrücke erzeugt werden (jeweils über einem geeigneten Terminalalphabet, das Sie nicht angeben müssen):

a) $r_1 =$ (a|b)(a|b)

b) $r_2 =$a(a|b)|b(a|b)

c) $r_3 =$(ab*)*

d) $r_4 =$(aa|b)*

e) $r_5 =$(D|d)(er|ie|as)

f) $r_6 =$(+|-)?[0-9]+

g) $r_7 =$[0-9A-F]+

Teilaufgabe 3.1.2 3 Punkte

Geben Sie die regulären Ausdrücke an, welche die folgenden formalen Sprachen erzeugen (jeweils über einem geeigneten Terminalalphabet, das Sie nicht angeben müssen):

a) $L_8 = \{$Meier, Meir, Meyer, Meyr, Maier, Mair, Mayer, Mayr$\}$

b) $L_9 = \{1€, 10€, 100€, 1000€, \ldots\}$

c) $L_{10} = \{a^n b^m \mid n, m \in \mathbb{N}_0\}$

d) $L_{11} = \{a^n b^m \mid n, m \in \mathbb{N}\}$

e) $L_{12} = \{(ab)^n \mid n \in \mathbb{N}\}$

f) $L_{13} = \{a, b\}^*$

g) $L_{14} = \{a^n \mid n \in \mathbb{N}_0\} \cup \{b^n \mid n \in \mathbb{N}_0\}$

h) $L_{15} = \{a^n \mid n \in \mathbb{N}\} \cup \{b^n \mid n \in \mathbb{N}\}$

Teilaufgabe 3.1.3 3 Punkte

Geben Sie die **regulären** Grammatiken an, welche die folgenden Sprachen erzeugen:

a) G_1 mit $\mathscr{L}(G_1) = L_1$

b) G_3 mit $\mathscr{L}(G_3) = L_3$

c) G_4 mit $\mathscr{L}(G_4) = L_4$

d) G_{12} mit $\mathscr{L}(G_{12}) = L_{12}$

Teilaufgabe 3.1.4 4 Punkte

Geben Sie die **regulären** Grammatiken an, welche die folgenden Sprachen erzeugen:

a) G_{11} mit $\mathscr{L}(G_{11}) = L_{11}$

b) G_{10} mit $\mathscr{L}(G_{10}) = L_{10}$

c) G_7 mit $\mathscr{L}(G_7) = L_7$

d) G_6 mit $\mathscr{L}(G_6) = L_6$

Aufgabe 3.2 Reguläre Ausdrücke für Datentypen

Folgende Liste regulärer Ausdrücke beschreibt die für eine Programmiersprache verwendeten Datentypen.

a) `[0]|[-+]?[1-9][0-9]*`

b) `\+?[1-9][0-9]*`

c) `[A-Za-z0-9\-\.]{1,64}`

d) `[^\s]+([\s]?[^\s]+)*`

e) `-?[0-9]{4}(-(0[1-9]|1[0-2])(-(0[0-9]|[1-2][0-9]|3[0-1]))?)?`

f) `([01][0-9]|2[0-3]):[0-5][0-9]:[0-5][0-9](\.[0-9]+)?`

Teilaufgabe 3.2.1 2 Punkte

Geben Sie für **jeden** der regulären Ausdrücke a)-c) jeweils **3** Beispiele für Worte an, welche durch den regulären Ausdruck beschrieben bzw. nicht beschrieben werden.

Teilaufgabe 3.2.2 3 Punkte

Geben Sie für **jeden** der regulären Ausdrücke d)-f) jeweils **3** Beispiele für Worte an, welche durch den regulären Ausdruck beschrieben bzw. nicht beschrieben werden.

Teilaufgabe 3.2.3 2 Punkte

Beschreiben Sie die für jeden Datentyp zulässigen Eingaben mit Ihren eigenen Worten und geben Sie an, was dieser darstellen könnte.

Aufgabe 3.3 The Hound of the Baskervilles

Um diese Aufgabe lösen zu können, verwenden Sie die Datei `ACDoyle_Hound-of-the-Baskervilles.txt` welche in Moodle zur Verfügung steht.

Außerdem benötigen Sie eine Linux/Unix-Shell, Cygwin unter Windows oder eine andere Windows-Grep-Lösung, einen Texteditor oder ein Online-Tool wie z.B. RegExr

Hinweise:

- Zählen Sie die Anzahl Ihrer Resultate (z.B. via Option -c) und sehen Sie sich diese an.
- Die Musterlösung geben eine mögliche Lösung an, andere Möglichkeiten gibt es sicher auch!

Teilaufgabe 3.3.1 3 Punkte

Wie oft werden die Helden (Sherlock Holmes und Dr. John H. Watson) im Dokument jeweils erwähnt? Konkret:

a) Wie oft korrekt angesprochen (Titel bzw. Mr.)?

b) Wie oft nur mit dem Nachnamen?

c) Wie oft nur nur mit dem Vornamen?

Teilaufgabe 3.3.2 3 Punkte

Dann noch ein paar Statistiken. Finden Sie jeweils die Anzahl der

a) direkten Reden

b) Buchstaben

c) Zahlen (die aus einer oder mehreren Ziffern bestehen)

im Dokument.

Teilaufgabe 3.3.3 2 Punkte

Finden Sie mit Hilfe eines **hübschen, bisher noch nicht gefragten** regulären Ausdrucks Ihrer Wahl noch etwas spannendes heraus!

Aufgabe 3.4 DEAs und NEAs

Wie betrachten im folgenden die Automaten A_2, A_3, A_4. In Abbildung 1 ist jeweils ihr Zustandsübergangsdiagramm dargestellt.

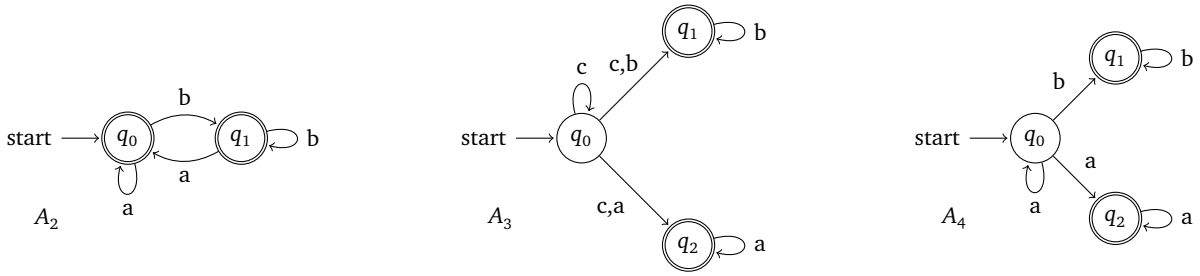

Abbildung 1: Zustandsübergangsdiagramme von A_2, A_3, A_4

Teilaufgabe 3.4.1 1 Punkt

Geben Sie für jeden der Automaten an, ob er ein deterministischer endliche Akzeptor, oder ein nichtdeterministischer endlicher Akzeptor ist. Begründen Sie Ihre Meinung.

Teilaufgabe 3.4.2 2 Punkte

Geben Sie für jeden der Automaten

a) das Eingabealphabet

b) die Zustandsmenge,

c) die Finalmenge,

d) die Zustandsübergangsfunktion in tabellarischer Form an.

Teilaufgabe 3.4.3 2 Punkte

Geben Sie für jeden Automaten alle Zustände an, welche bei der Verarbeitung der Worte bbb und aab durchlaufen werden. Entscheiden Sie, ob die Worte akzeptiert werden oder nicht.
Welche Methode Sie zur Lösung dieser Aufgabe verwenden, ist egal. Achten Sie jedoch darauf, dass Sie es geeignet darstellen, falls sich der Automat in mehreren Zuständen gleichzeitig befindet.

Teilaufgabe 3.4.4 2 Punkte

Geben Sie für jeden der Automaten (wenn möglich) 3, zu den Wörtern aus Aufgabe 3.4.3 verschiedene Worte über dem Alphabet $\Sigma = \{a, b, c\}$ an

a) die akzeptiert werden,

b) die nicht akzeptiert werden.

Benutzen Sie Ihre Ergebnisse, um für jeden Automaten dessen akzeptierte Sprache anzugeben.

AUFGABE 3.5 SPRACHE VON ENDLICHEN AUTOMATEN, 3 PUNKTE

Gegeben Sei das Alphabet $\Sigma = \{x, y, z\}$. Gegeben seinen außerdem die folgenden Automaten:

- $A_1 = (Q, \Sigma, \delta_1, F, q_0)$ mit $Q = \{q_0, q_1, q_2\}, F = \{q_0\}$ und δ_1 gegeben durch:

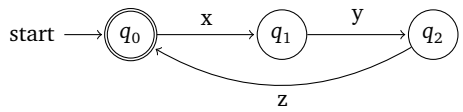

- $A_2 = (Q, \Sigma, \delta_2, F, q_0)$ mit $Q = \{q_0, q_1, q_2, q_3\}, F = \{q_3\}$ und δ_2 gegeben durch:

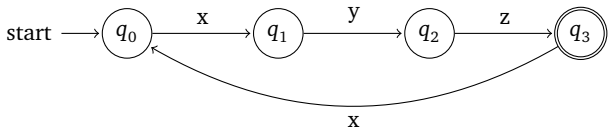

- $N_3 = (Q, \Sigma, \delta_3, F, q_0)$ mit $Q = \{q_0, q_1, q_2\}, F = \{q_0\}$ und δ_3 gegeben durch:

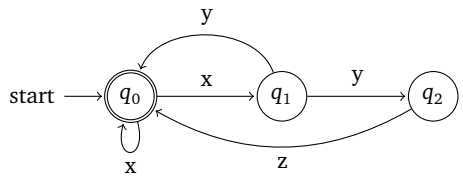

TEILAUFGABE 3.5.1 2 PUNKTE

Betrachten Sie die Worte $\omega_1 = xyz$ und $\omega_2 = xyxyz$. Geben Sie für alle Automaten alle Zustände an, die bei der Verarbeitung der Worte jeweils durchlaufen werden. Entscheiden Sie anschließend, ob die Wort akzeptiert werden oder nicht.

Welche Methode Sie zur Lösung dieser Aufgabe verwenden, ist egal. Achten Sie jedoch darauf, dass Sie es geeignet darstellen, falls sich der Automat in mehreren Zuständen gleichzeitig befindet.

TEILAUFGABE 3.5.2 2 PUNKTE

Geben Sie für jeden der Automaten die Sprache an, welche er akzeptiert.

Aufgabe 3.6 Reguläre Ausdrücke und DEAs

Betrachten Sie das Alphabet $\Sigma = \{a, b\}$ sowie die Sprachen, die aus den folgenden regulären Ausdrücken (bekannt aus Aufgabe 2.9) erzeugt werden:

a) $L_1 = \mathcal{L}(r_1)$ mit $r_1 = (a|b)(a|b)$

b) $L_2 = \mathcal{L}(r_2)$ mit $r_2 = (a|b)^*$

c) $L_3 = \mathcal{L}(r_3)$ mit $r_3 = a^*|b^*$

d) $L_4 = \mathcal{L}(r_4)$ mit $r_4 = a^+|b^+$

e) $L_5 = \mathcal{L}(r_5)$ mit $r_5 = a^*b^*$

f) $L_6 = \mathcal{L}(r_6)$ mit $r_6 = a^+b^+$

g) $L_7 = \mathcal{L}(r_7)$ mit $r_7 = (ab^*)^*$

h) $L_8 = \mathcal{L}(r_8)$ mit $r_8 = (aa|b)^*$

Teilaufgabe 3.6.1 4 Punkte

Geben Sie die DEAs A_1, A_2, A_3, A_4 an, welche die Sprachen L_1, L_2, L_3, L_4 akzeptieren.

Teilaufgabe 3.6.2 4 Punkte

Geben Sie die DEAs A_5, A_6, A_7, A_8 an, welche die Sprachen L_5, L_6, L_7, L_8 akzeptieren.

Aufgabe 3.7 Paritätscode

Zur Fehlererkennenung bei einer Datenübertragung wird oft der *Paritätscode* genutzt.

Die Grundidee des Paritätscodes ist, ausschließlich Datenpakete zu versenden, die eine gerade Anzahl Einsen aufweisen. Hierzu werden die Datenpakete vor dem Versenden um ein Paritätsbit ergänzt, das die Gesamtzahl der Einsen bei Bedarf gerade werden lässt.

Ein Übertragungsfehler wird dadurch erkannt, dass die Anzahl der Einsen ungerade ist. Ist die Anzahl der Einsen gerade, wurde das Paket korrekt übertragen.

Das vor der Übertragung hinzuzufügende Paritätsbit berechnet sich wie folgt:

- 1, falls die Anzahl der Einsen im Datenpaket ungerade ist
- 0, falls die Anzahl der Einsen im Datenpaket gerade ist

Ein Paritätscode der Länge 4 versieht also die ersten 3 Datenbits mit einem 4. Paritätsbit, so dass die Pakete insgesamt wie folgt aussehen: $000|0, 001|1, 010|1, \ldots$

Teilaufgabe 3.7.1 2 Punkte

Konstruieren Sie einen DEA A_P, der die Integrität eines empfangenen Datenpakets überprüft und alle korrekt übertragenen Wörter **beliebiger Länge** akzeptiert. Wurde ein einzelnes Bit des Datenpakets während der Übertragung verfälscht, so soll der Automat das Eingabewort ablehnen.

Das leere Wort soll ebenfalls abgelehnt werden.

Teilaufgabe 3.7.2 1 Punkt

Wie verhält sich der von Ihnen konstruierte Automat, falls zwei Bits während der Datenübertragung verfälscht wurden? Weist er dieses falsche Wort auch zurück? Begründen Sie Ihre Aussage.

Teilaufgabe 3.7.3 2 Punkte

Konstruieren Sie eine **reguläre** Grammatik G_P, welche alle korrekt übertragenen Wörter **beliebiger Länge** (also mit einer geraden Anzahl von 1en) erzeugt. Das leere Wort soll nicht in der Sprache enthalten sein.

Aufgabe 3.8 Die Sprache L_x

Betrachten Sie die Sprache L_x die mit Hilfe eines regulären Ausdrucks definiert ist:

$$L_x = \mathscr{L}(r_x) \qquad \text{und } r_x = ((ab)|(cd))^*$$

Teilaufgabe 3.8.1 3 Punkte

Geben Sie den DEA A_x an, der L_x akzeptiert. Zusatzanforderung an A_x: alle (auch nicht akzeptierte) Worte sollen komplett eingelesen werden.

Teilaufgabe 3.8.2 2 Punkte

Geben Sie die **reguläre** Grammatik G_x an, die L_x erzeugt.

Aufgabe 3.9 Das Ende ist abc

Gegeben sei die Sprache L_1 aller Wörter über $\Sigma = \{a, b, c\}$, die auf abc enden:
$L_1 = \{\omega \in \Sigma^* \mid \omega = xabc, x \in \Sigma^*\}$

Teilaufgabe 3.9.1 1 Punkt

Geben Sie einen regulären Ausdruck r_1 an, der L_1 erzeugt.

Teilaufgabe 3.9.2 2 Punkte

Geben Sie einen nichtdeterministischen endlichen Automaten N_1 an, für den $\mathscr{L}(N_1) = L_1$ gilt. Achten Sie darauf, dass Ihr Automat nichtdeterministische Elemente enthält.

Teilaufgabe 3.9.3 2 Punkte

Geben Sie einen deterministischen endlichen Automaten $A_1 = (\Sigma, Q, \delta, q_0, F)$ an, für den $\mathscr{L}(A_1) = L_1$ gilt.

AUFGABE 3.10 01 AM BEGINN UND ENDE (KLAUSUR WS 15/16)

Wir betrachten das Alphabet $\Sigma = \{0,1\}$ und Sprache $L_x \subseteq \Sigma^*$, welche alle Wörter aus Σ^* enthält, die sowohl mit 01 beginnen, als auch mit 01 enden.

Beispielhafte Wörter aus L_x sind 0101, 01001, 0101011100101.

Die Wörter 01, 01111, 001101 gehören **nicht** zu L_x.

TEILAUFGABE 3.10.1 1 PUNKT

Geben Sie die Sprache L_x formal, als Menge in der deskriptiven Form an.

TEILAUFGABE 3.10.2 1 PUNKT

Geben Sie den regulären Ausdruck r_x an, welcher die Sprache L_x erzeugt, für welchen also $\mathscr{L}(r_x) = L_x$ gilt. Sie können hierfür eine formale, oder eine Unix-ähnliche Syntax wählen.

TEILAUFGABE 3.10.3 3 PUNKTE

Geben Sie den NEA N_x an, welcher L_x akzeptiert, für welchen also $\mathscr{L}(N_x) = L_x$ gilt. Achten Sie darauf, dass Ihr Automat mindestens ein nichtdeterministisches Element enthält!

TEILAUFGABE 3.10.4 3 PUNKTE

Geben Sie den DEA A_x an, welcher L_x akzeptiert, für welchen also $\mathscr{L}(A_x) = L_x$ gilt.

Zusatzanforderung an A_x: alle (auch nicht akzeptierte) Eingabewörter sollen komplett eingelesen werden. Bei Nicht-Akzeptanz soll A_x in einem beliebigen Nicht-Final-Zustand enden.

TEILAUFGABE 3.10.5 2 PUNKTE

Gegeben sei $\omega_1 \in L_x$ mit $\omega_1 = 010101$.

a) Geben Sie **alle** Zustände an, welche A_x bei der Verarbeitung von ω_1 durchläuft.

b) Geben Sie **alle** Zustände an, welche N_x bei der Verarbeitung von ω_1 durchläuft.

TEILAUFGABE 3.10.6 3 PUNKTE

a) Geben Sie die reguläre Grammatik G_x an, welche L_x erzeugt.

b) Leiten Sie mit Hilfe der Regeln von G_x das Wort $\omega = 0100101$ aus dem Startsymbol ab.

Hinweis: Die Menge Ihrer Regeln hat keinen Einfluss auf die Punktgebung, alle Punkte erhalten Sie allerdings nur für *reguläre* Regeln.

Aufgabe 3.11 Schlechte Passwörter

Eine der am häufigsten genutzten Passwörter im deutschsprachigen Raum ist „qwertz“. Die IT-Abteilung in der Sie Ihr Praktikum verbringen, möchte deshalb in einem schwach gesicherten System, das als Passwörter nur Kleinbuchstaben erlaubt, alle Passwörter ausmerzen, die gleich, oder ähnlich zu „qwertz“ sind und betreut Sie mit verschiedenen Aufgaben.

Teilaufgabe 3.11.1 Ein DEA für qwertz, 3 Punkte

Konstruieren Sie einen DEA A_Q, der eine eingegebene beliebig lange Zeichenkette genau dann akzeptiert, falls Sie identisch zu „qwertz“ sind.

Konstruieren Sie Ihren Automaten so, dass er während des Lesens eines Wortes ungleich „qwertz“ nicht abbricht, sondern das Wort komplett einliest und sich nach Abschluss des Einlesens in einem gesonderten Fehlerzustand befindet.

Teilaufgabe 3.11.2 Ein NEA für *qwertz*, 2 Punkte

Konstruieren Sie einen NEA N_Q, der eine eingegebene beliebig lange Zeichenkette genau dann akzeptiert, falls Sie als Teilwort den String „qwertz“ enthält.

Beispiele: qwertz, qwertzz, asdfqwertzuio werden akzeptiert, qwert, quwertz, ertz werden nicht akzeptiert.

Teilaufgabe 3.11.3 Ein DEA für *wer*, 3 Punkte

Konstruieren Sie einen DEA A_W, der eine eingegebene beliebig lange Zeichenkette genau dann akzeptiert, falls Sie als Teilwort den String „wer“ enthält.

Beispiele: wer, qwertz, werwolf werden akzeptiert, we, wetr, erw werden nicht akzeptiert.

Teilaufgabe 3.11.4 Ein DET zur Erkennung von *wer*, 3 Punkte

Konstruieren Sie einen DET T_W, der als Eingabe eine beliebig lange Zeichenkette annimmt und auf dem Ausgabeband für jedes Zeichen ein Kästen schreibt. T_W soll ein markiertes Kästchen schreiben, wenn als Teilwort der String „wer“ gelesen wurde. Insbesondere soll jedes Vorkommen von „wer“ mit einem markierten Kästchen signalisiert werden.

Es bleibt Ihnen überlassen, ob Sie T_W als Mealy- oder als Moore-Automat konstruieren.

Beispiele:

- wer → □□⊠
- qwertz → □□□ ⊠ □□
- werwolfwer → □□ ⊠ □□□□□□□⊠
- wetr → □□□□

AUFGABE 3.12 INFORMATIK-STUDIENGÄNGE

Die von der Fakultät für Informatik angebotenen Bachelor-Studiengänge sind Allgemeine Informatik (ain), Automobilinformationstechnik (ait), Gesundheitsinformatik (gib) und Wirtschaftsinformatik (win). Wir betrachten das Alphabet aller Kleinbuchstaben $\Sigma = \{a, b, \ldots, z\}$.

TEILAUFGABE 3.12.1 EIN NEA FÜR DIE INFORMATIK, 3 PUNKTE

Konstruieren Sie einen NEA N_I, der eine eingegebene beliebig lange Zeichenkette über dem Alphabet Σ genau dann akzeptiert, falls Sie als Teilwort mindestens einen der Strings der genannten Bachelorstudiengänge (ain, ait, gib, win) enthält.

Konstruieren Sie den Automaten so, dass er möglichst wenige Zustände enthält.

Beispiele: ain, aitain, gggibbbb werden akzeptiert, aiai, wien, xyzwi werden nicht akzeptiert.

TEILAUFGABE 3.12.2 EIN DEA FÜR *(A|W)IN*, 3 PUNKTE

Konstruieren Sie einen DEA A_I, der eine eingegebene beliebig lange Zeichenkette genau dann akzeptiert, falls Sie als Teilwort mindestens einen der Strings ain oder win enthält.

Beispiele: aaain, winner, winainait werden akzeptiert, mai, mawi, xaxixn werden nicht akzeptiert.

TEILAUFGABE 3.12.3 EIN DET ZUR ERKENNUNG VON *(A|W)IN*, 3 PUNKTE

Konstruieren Sie einen DET T_I, der als Eingabe eine beliebig lange Zeichenkette annimmt und auf dem Ausgabeband für jedes Zeichen ein Kästen ausgibt. T_I soll ein markiertes Kästchen schreiben, wenn als Teilwort der String ain oder win vollständig gelesen wurde. Es soll also jedes Vorkommen von ain oder win mit einem markierten Kästchen signalisiert werden.

Es bleibt Ihnen überlassen, ob Sie T_I als Mealy- oder als Moore-Automat konstruieren.

Beispiele:

- ain → □□⊠
- winner → □□ ⊠ □□□
- winainait → □□ ⊠ □□ ⊠ □□□
- aixn → □□□□